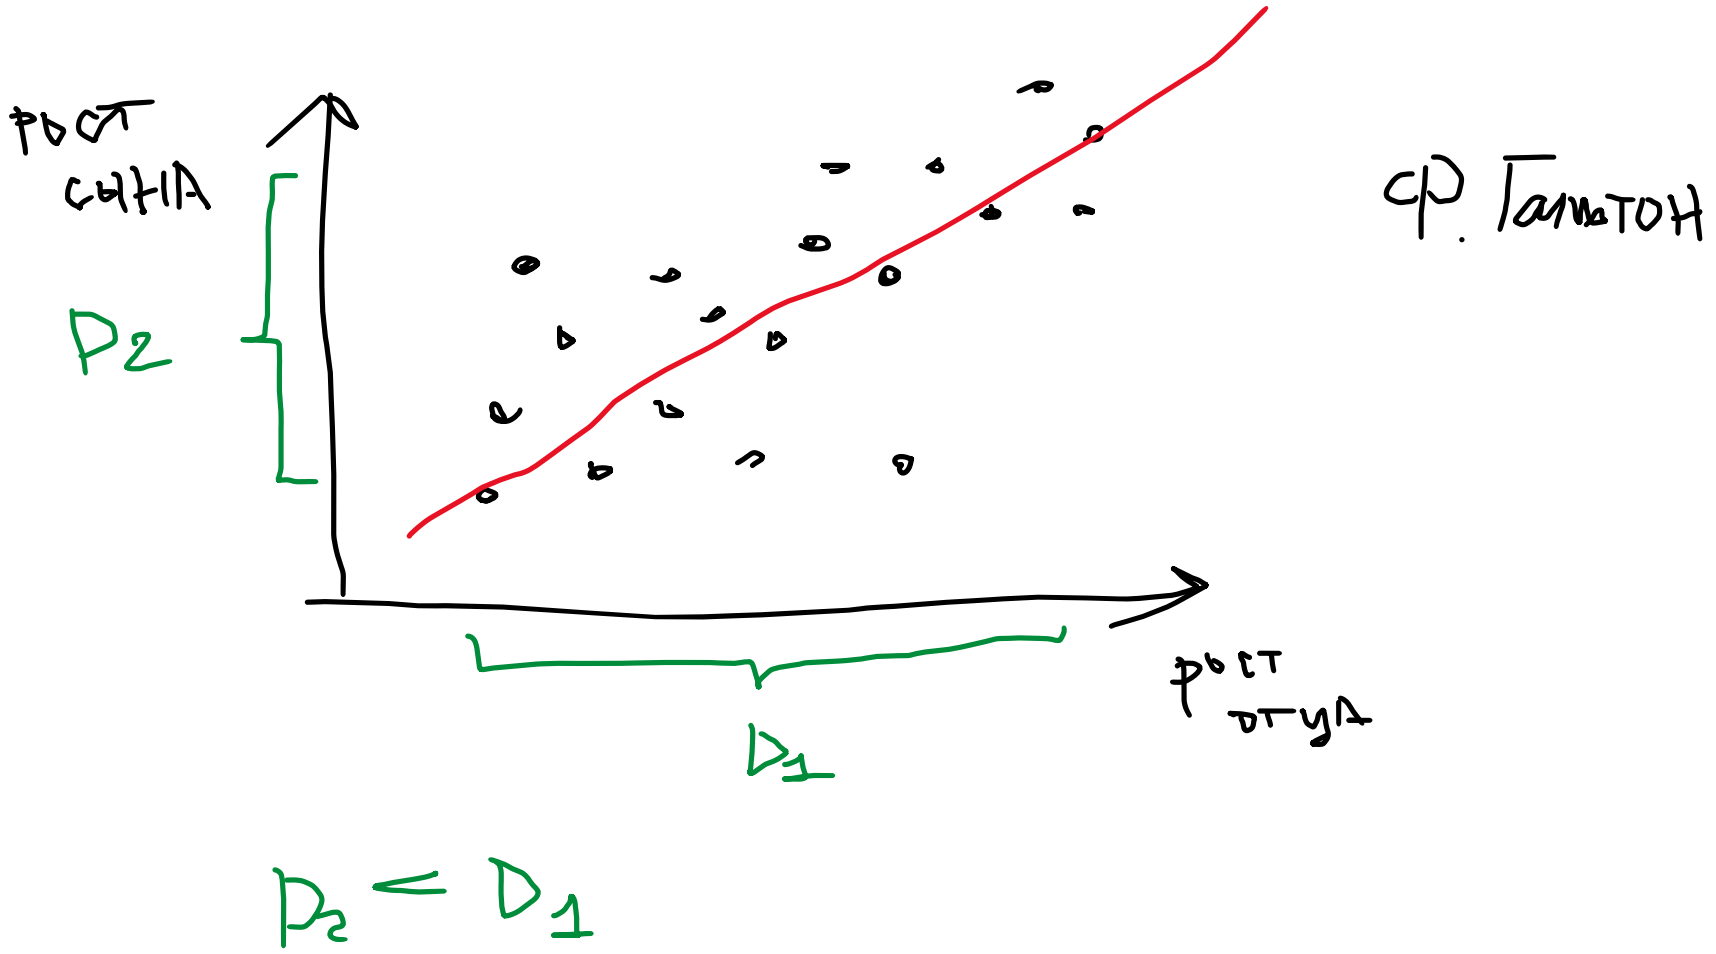
Вокруг да около линейной регрессии

Почему «регрессия»?



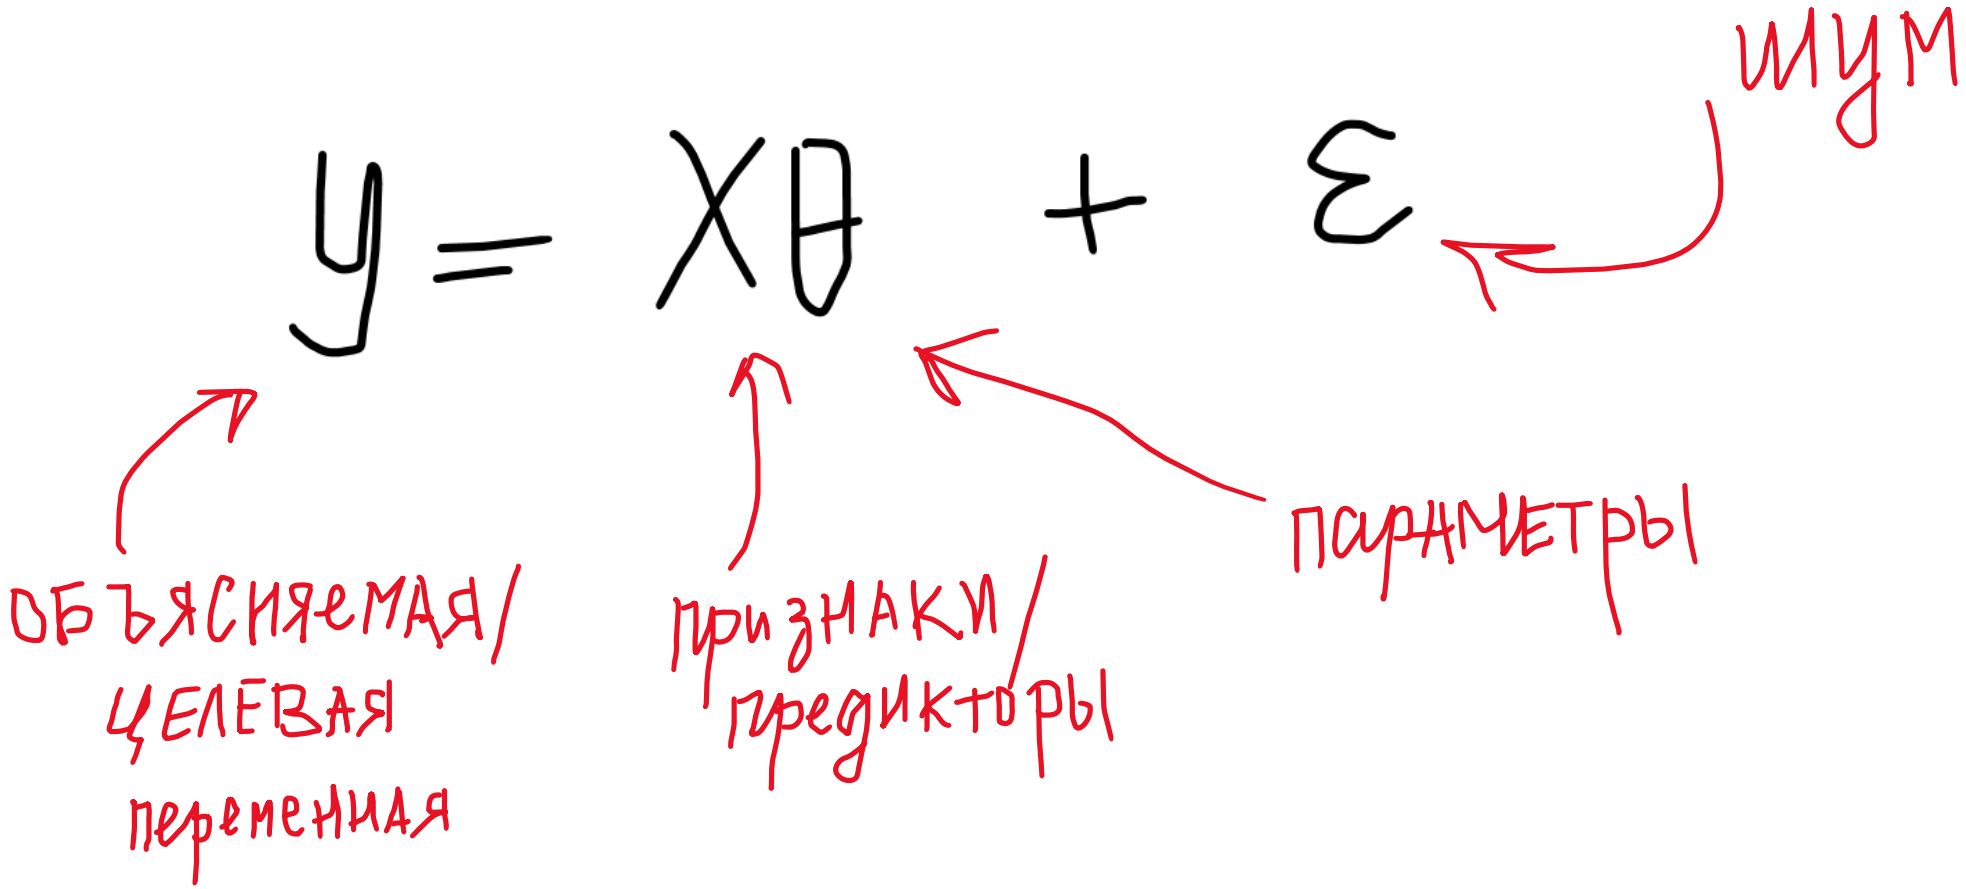
Со временем зависимая переменная «регрессирует» к среднему

Постановка

$$y = X\theta + \varepsilon$$

$$y_i = 1 \cdot \theta_0 + X_{i1} \cdot \theta_1 + X_{i2} \cdot \theta_2 + \dots + X_{ik} \cdot \theta_k + \varepsilon_i$$

Постановка


$y = X\theta + \varepsilon$
шум
объясняемая/
целевая
переменная
признаки/
предикторы
параметры

Постановка

$$y \in R^n \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} \qquad X \in R^{n \times k} \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1k} \\ x_{21} & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots \\ x_{n1} & \dots & \dots & x_{nk} \end{pmatrix}$$

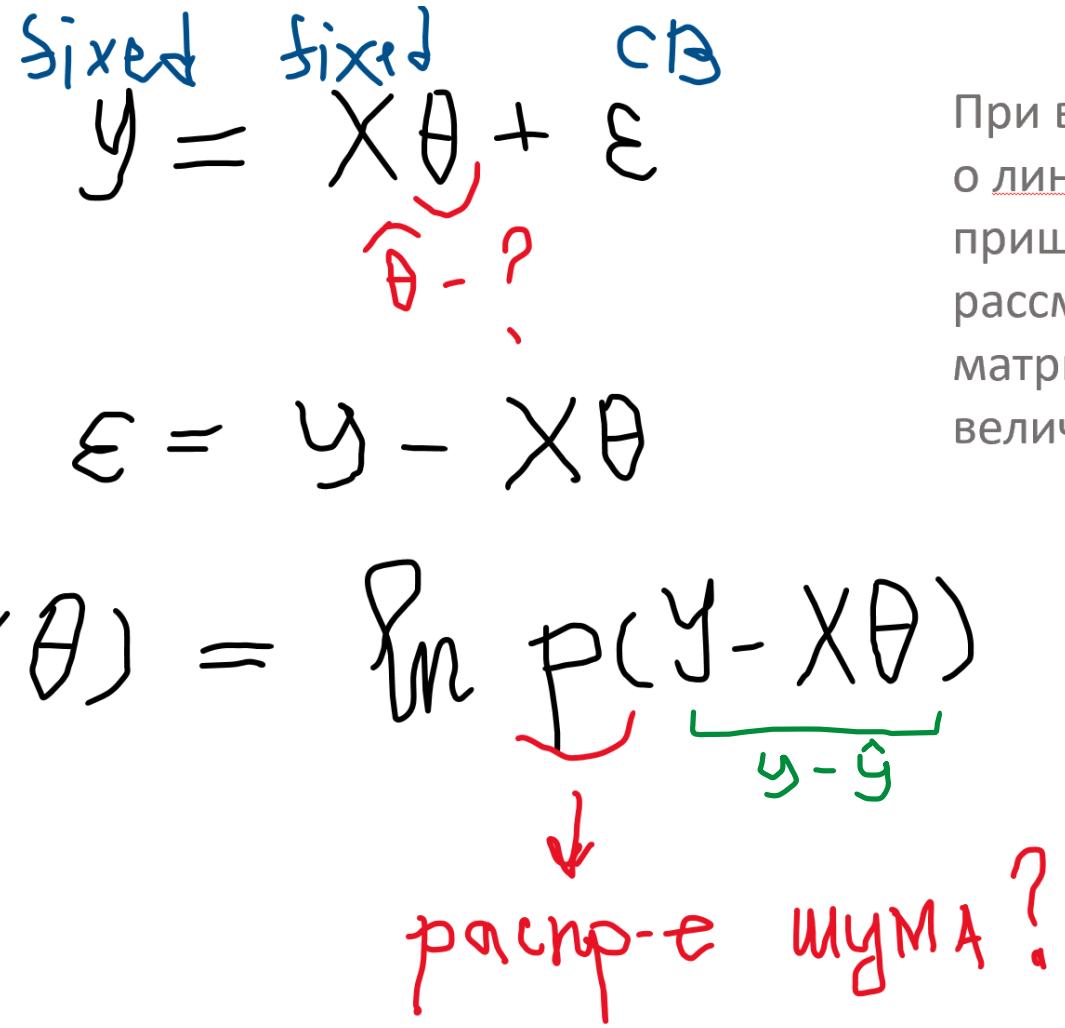
$$\theta \in R^k \begin{pmatrix} \theta_1 \\ \theta_2 \\ \dots \\ \theta_k \end{pmatrix} \qquad \varepsilon \in R^n \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{pmatrix}$$

К концепции оценки параметров в классической линейной регрессии можно прийти по-разному:

- Можно думать об этом как о **минимизации MSE** в машинном обучении
- Можно как об **оценке ММП**
- Можно с точки зрения **«здравого смысла»**

Все это, тем не менее, не противоречит друг другу, а хорошо дополняет понимание модели

Линейная регрессия: ММП



При выводах формул и рассуждениях о лин. регрессии в контексте работы с пришедшей выборкой, X – все-таки рассматривается как фиксированная матрица наблюдений, а не случайная величина

Линейная регрессия: ММП и МНК

Пусть: $\varepsilon \overset{iid}{\sim} N(0, \sigma^2)$, тогда

$$f(\varepsilon_i) = \frac{1}{\sqrt{2\pi\sigma_i^2}} \cdot \exp \frac{-\varepsilon_i^2}{2\sigma_i^2}$$

$$L = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \cdot \exp^{-\frac{1}{2\sigma^2} \cdot \sum \varepsilon_i^2}$$

$$\ln L = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum (y_i - \hat{y}_i(\theta))^2 \to \max_{\theta}$$

$$\sum (y_i - \hat{y}_i)^2 \to \min_{\theta} \quad \Rightarrow \text{МНК}$$

Линейная регрессия: оценки ММП (МНК)

Теорема:

$$\varepsilon \sim N(0, \sigma^2), \text{ тогда}$$

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

Сложность такой операции: $O(K^2 N + K^3)$, поэтому зачастую в ML используют численные методы

Док-во

$$(y - X\theta)^T (y - X\theta) \to \min_{\theta}$$

$$\frac{\partial (y - X\theta)^T (y - X\theta)}{\partial \theta} = \frac{\partial (y^T y + \theta^T X^T X \theta - \theta^T X^T y - y^T X \theta)}{\partial \theta} =$$

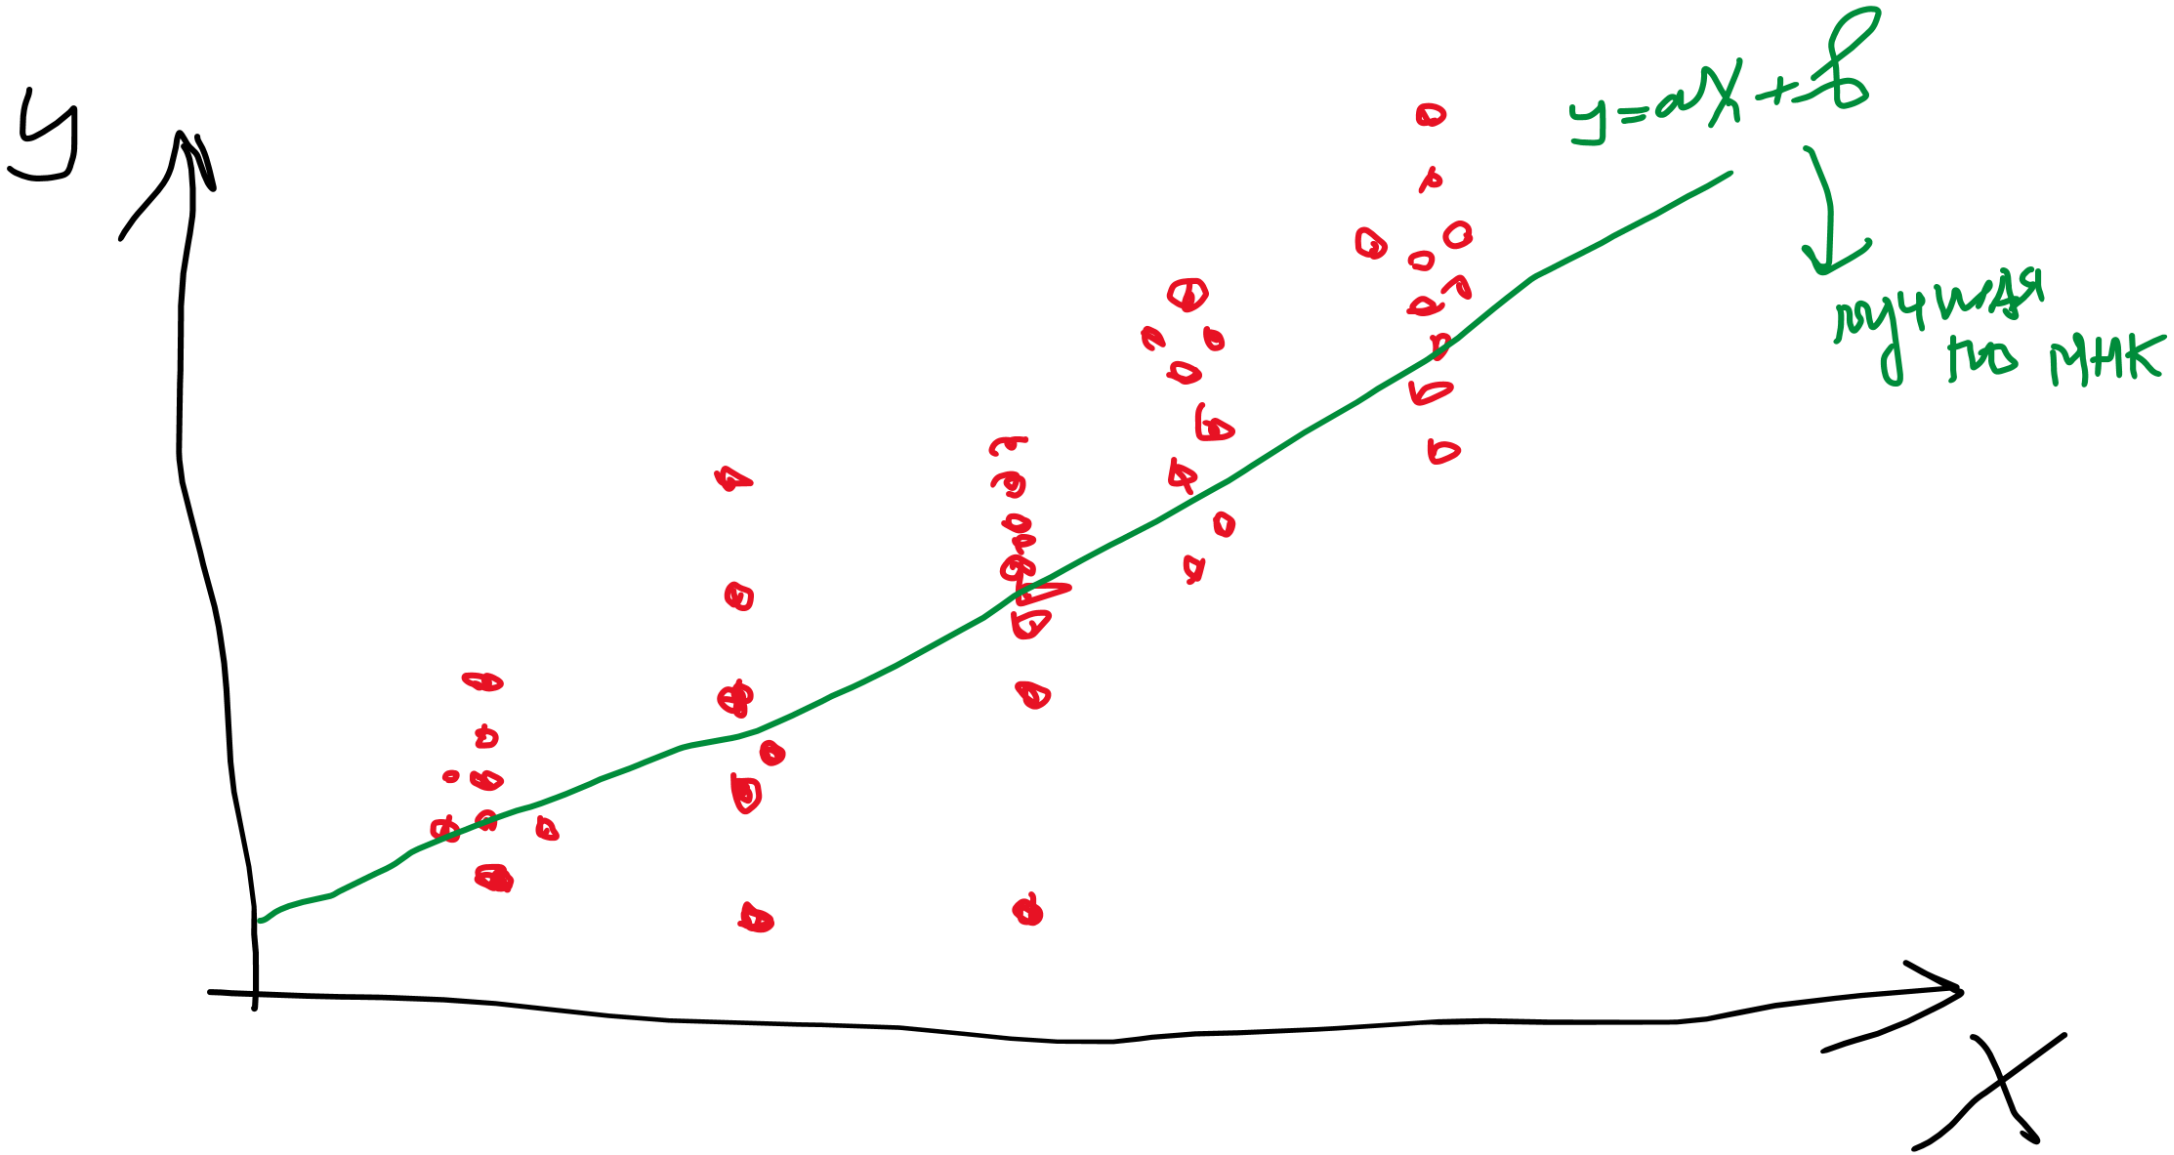
$$= 2X^T X\theta - 2X^T y = 0$$

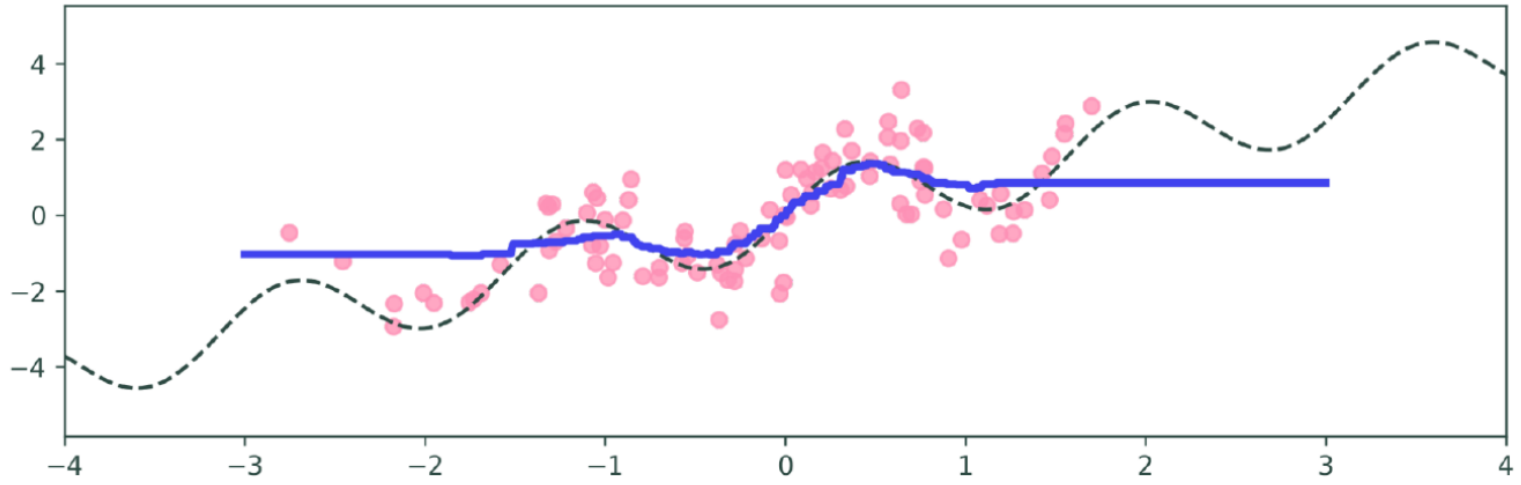
$$\hat{\theta} = (X^T X)^{-1} X^T y$$

Минимум MSE и условное мат.ожидание

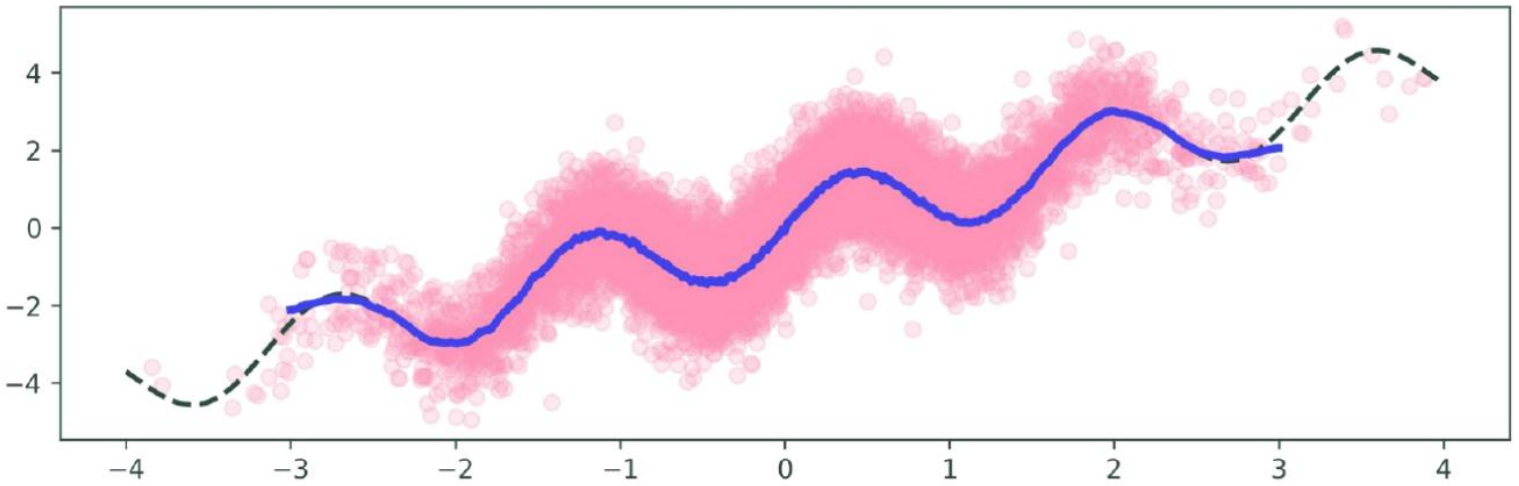
- **Point:** классическая линейная регрессия предсказывает условное среднее зависимой переменной

- Почему?


y
y=ax+b
лучшая по МНК
x



Предсказание метода k ближайших соседей при $k = 25$ и $n = 100$



Предсказание метода k ближайших соседей при $k = 500$ и $n = 100000$

Источник: лекция Максима Николаева, ШАД: https://disk.yandex.ru/d/b2rOMFWfsqqBLA

Док-во

$$L(y, \hat{y}) = (y - \hat{y})^2$$

Теоретическая ошибка:

$$MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

На практике ошибка зависит от пришедшей выборки:

$$E[(y - \hat{y})^2 | x] =$$

$$= \int (y - \hat{y})^2 f(y|x) dy \longrightarrow \min_{\hat{y}}$$

Док-во

FOC:

$$\frac{\partial E[(y-\hat{y})^2 | x]}{\partial \hat{y}} = -2 \int (y-\hat{y}) f(y|x) dy = 0$$

const

$$\int y f(y|x) dy - \int \hat{y} f(y|x) dy = 0$$

$$E(y|x) - \hat{y} \cdot 1 = 0 \Rightarrow \boxed{\hat{y} = E(y|x)}$$

по опр-ю

- Методом KNN можно было бы решить подавляющее большинство задач в мире…

- Если бы не «проклятье размерности»!

Теорема Гаусса-Маркова

Если соблюдены условия Гаусса-Маркова, то МНК оценка линейной регрессии является **BLUE**

BLUE

Best Linear Unbiased Estimation

Теорема Гаусса-Маркова

Условия Г-М:

1. Модель правильно специфицирована;
2. Объясняющие переменные линейно независимы;
3. Ошибки независимы друг от друга;
4. Дисперсия ошибок одинакова;
5. Ошибки не зависят от наблюдений;
6. Мат. ожидание ошибок равно нулю.

Теорема Гаусса-Маркова

1. Модель **правильно специфицирована**

- Истинная зависимость от параметров правда линейная;
- Учтены все важные признаки

Иначе: проблема эндогенности

Теорема Гаусса-Маркова

2. Объясняющие переменные детерминированы и **линейно независимы**

- В данных нет мультиколлинеарности;
- Матрица X полного ранга

Иначе: оценки невозможно вычислить (нельзя взять обратную матрицу)

Теорема Гаусса-Маркова

2. Объясняющие переменные **детерминированы** и линейно независимы

- Предпосылка про детерминированность вводится для упрощения технических расчетов (от нее можно отказаться);
- Вводить ее или не вводить зависит от того, как Вы собираете выборку

Пример: Вы собрали з/п Data Scientist с определенными навыками. Затем захотели обновить выборку. Можно взять Data Scientist с такими же навыками, как в исходной выборке и посмотреть их з/п (X – детерминирован), а можно выбрать людей случайным образом (X – СВ)

Теорема Гаусса-Маркова

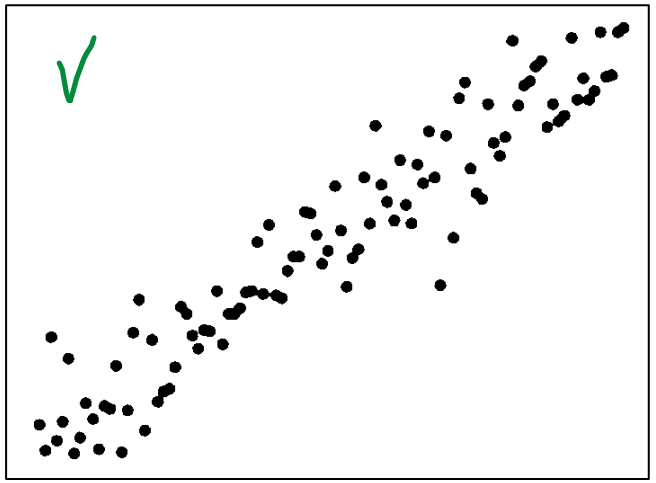
3. Случайные **ошибки не зависят друг от друга**

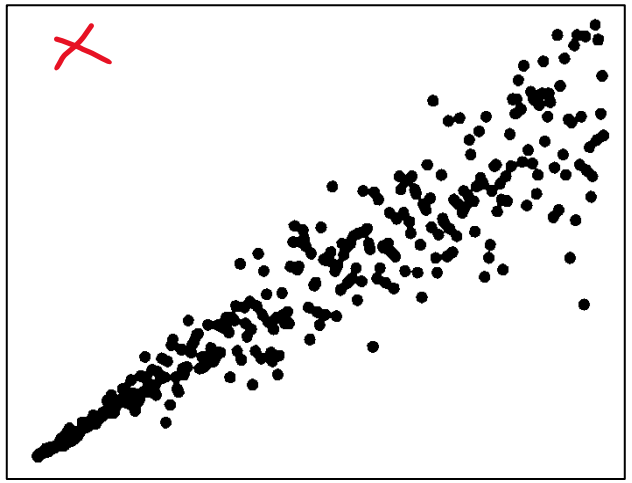
- Иначе говоря, отсутствует проблема автокорреляции
- Нарушается в панельных данных и временных рядах

Теорема Гаусса-Маркова

4. **Дисперсия** ошибок **одинакова**

- Иначе говоря, данные гомоскедастичны;
- Разброс ошибок в среднем постоянен





Теорема Гаусса-Маркова

5. Ошибки **не зависят от наблюдений**

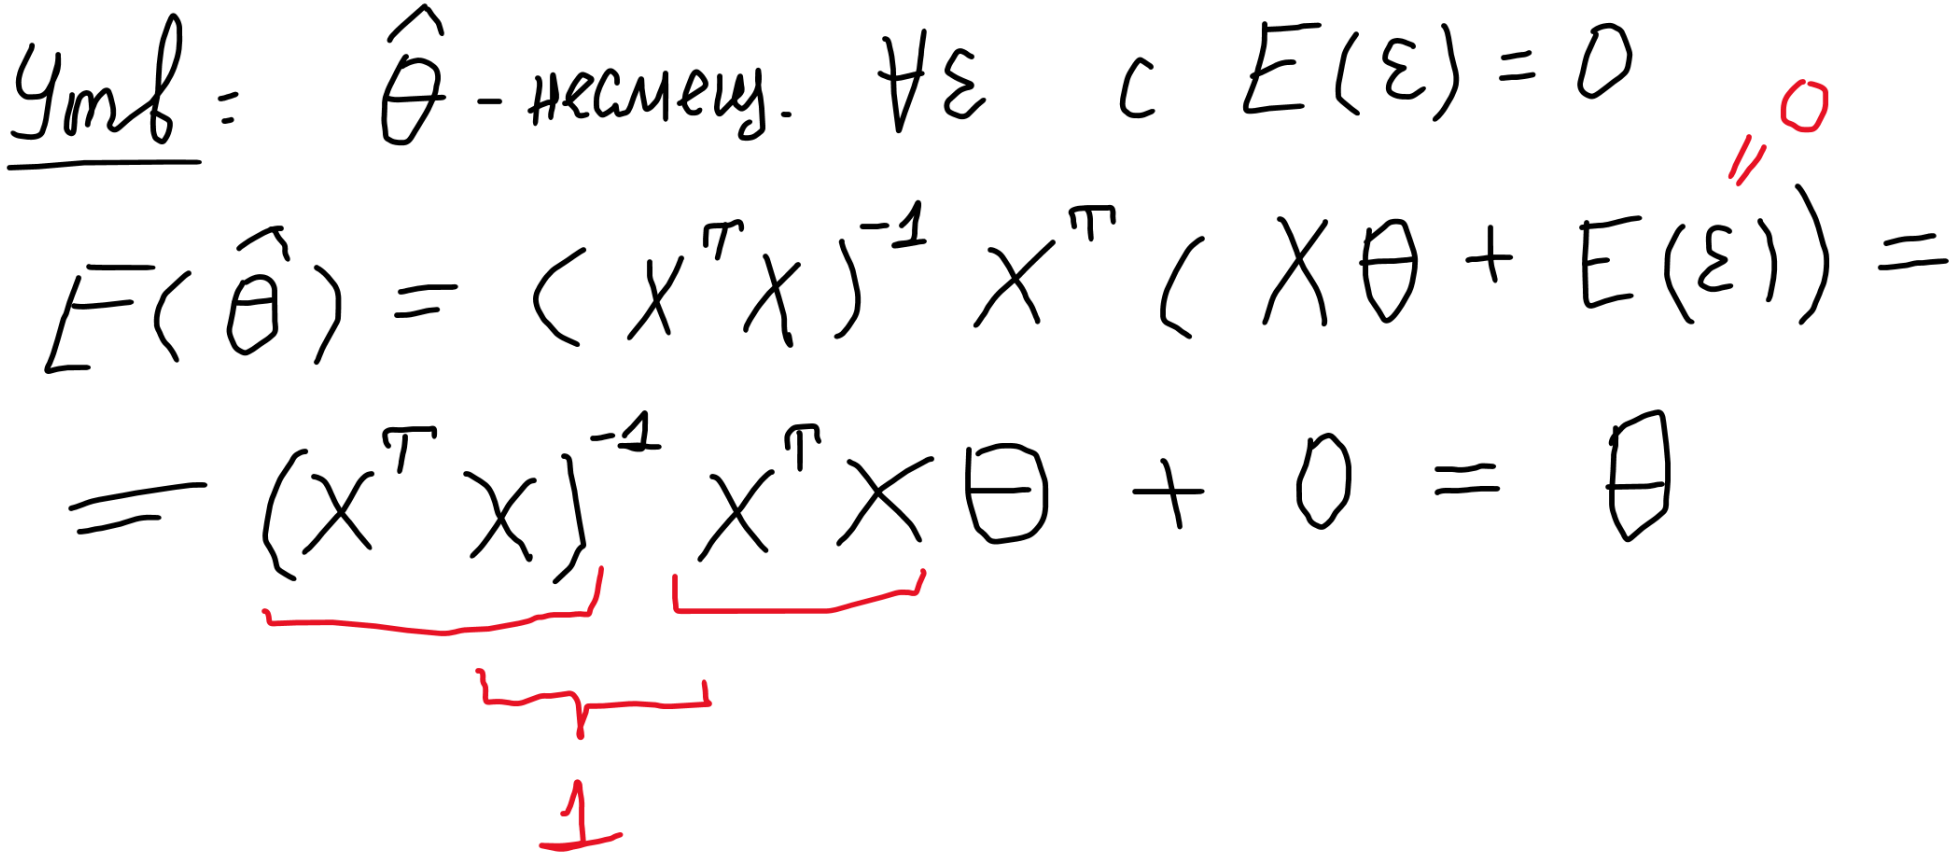
- Наблюдается экзогенность;
- Предпосылка может нарушаться, если есть пропущенная переменная, одновременность, ошибки измерения…

Теорема Гаусса-Маркова

6. **Мат. ожидание** ошибок равно **нулю**

- Прочие факторы могут приводит к отклонениям в ту или другую сторону, но в среднем это влияние компенсируется

Unbiased estimation



Best estimation

$y_{mb} = \mathrm{Var}(\theta) = \sigma (X^T X)^{-1}$

$\hat{\theta} = (X^T X)^{-1} X y \Rightarrow \hat{\theta} = (X^T X)^{-1} X (X\theta + \varepsilon) \Rightarrow \hat{\theta} = \underbrace{(X^T X)^{-1} X^T X}_{I} \theta + (X^T X)^{-1} X^T \varepsilon \Rightarrow$

$\Rightarrow \hat{\theta} = \theta + (X^T X)^{-1} X^T \varepsilon \Rightarrow \hat{\theta} - \theta = (X^T X)^{-1} X^T \varepsilon$

$\mathrm{Var}(\hat{\theta} - \theta) = E\left[\left((X^T X)^{-1} X^T \varepsilon \right) \left((X^T X)^{-1} X^T \varepsilon \right)^T \right] =$

$= E\left[(X^T X)^{-1} X^T \varepsilon \, \varepsilon^T X (X^T X)^{-1} \right] =$

$= (X^T X)^{-1} X^T \cdot E[\varepsilon \varepsilon^T] \cdot X (X^T X)^{-1} =$

$= \sigma \cdot \underbrace{(X^T X)^{-1} \cdot X^T X}_{I} \cdot (X^T X)^{-1} = \sigma (X^T X)^{-1}$

гомоскедастичность:

$E[\varepsilon \varepsilon^T] = \begin{pmatrix} \sigma & 0 & \dots & 0 \\ 0 & \ddots & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & \dots & & \sigma \end{pmatrix}$

Ecm= $\varepsilon \sim N(0, \sigma^2)$, TD

$\hat{\theta} \sim (\theta, \sigma^2 (X^T X)^{-1})$

Проверка базовых гипотез в линейной регрессии

Гипотеза о наличии связи

$$y_i = \beta_0 + \beta_1 x_1$$

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

Гипотеза о наличии связи

$$МНК = \sum (y_i - \hat{y}_i)^2 = \sum (y_i - \beta_0 - \beta_1 x_i)^2 \to \min_{\beta_0, \beta_1}$$

$$\begin{cases} \frac{\partial}{\partial \beta_0} = -2 \sum (y_i - \beta_0 - \beta_1 x_i) = 0 \\ \frac{\partial}{\partial \beta_1} = -2 x_i \sum (y_i - \beta_0 - \beta_1 x_i) = 0 \end{cases} \Rightarrow \begin{cases} \sum y - n\beta_0 - \beta_1 \sum x = 0 \\ \sum xy - \beta_0 \sum x - \beta_1 \sum x^2 = 0 \end{cases} \Rightarrow$$

$$\beta_0 = \frac{\sum y}{n} - \beta_1 \frac{\sum x}{n} = \bar{y} - \beta_1 \bar{x}$$

$$\Rightarrow \sum xy - \bar{y} \sum x + \beta_1 \bar{x} \sum x - \beta_1 \sum x^2 \Rightarrow \beta_1 = \frac{\sum (y_i - \bar{y}) x_i}{\sum (x_i - \bar{x}) x_i}$$

Гипотеза о наличии связи

$$\beta_1 = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} \leftarrow cov_{xy}$$

$$cov_{xy} = 0 \longleftrightarrow \beta_1 = 0$$

Гипотеза о наличии связи

$$T = \frac{\hat{\beta}_1}{\hat{\sigma}(\hat{\beta})} \sim t_{n-2}$$

Квадраты остатков

$$RSS = \sum (y_i - \hat{y}_i)^2$$

residual

Суммарная квадратичная оцененная ошибка прогноза полной модели лин. регрессии

$$TSS = \sum (y_i - \bar{y})^2$$

total

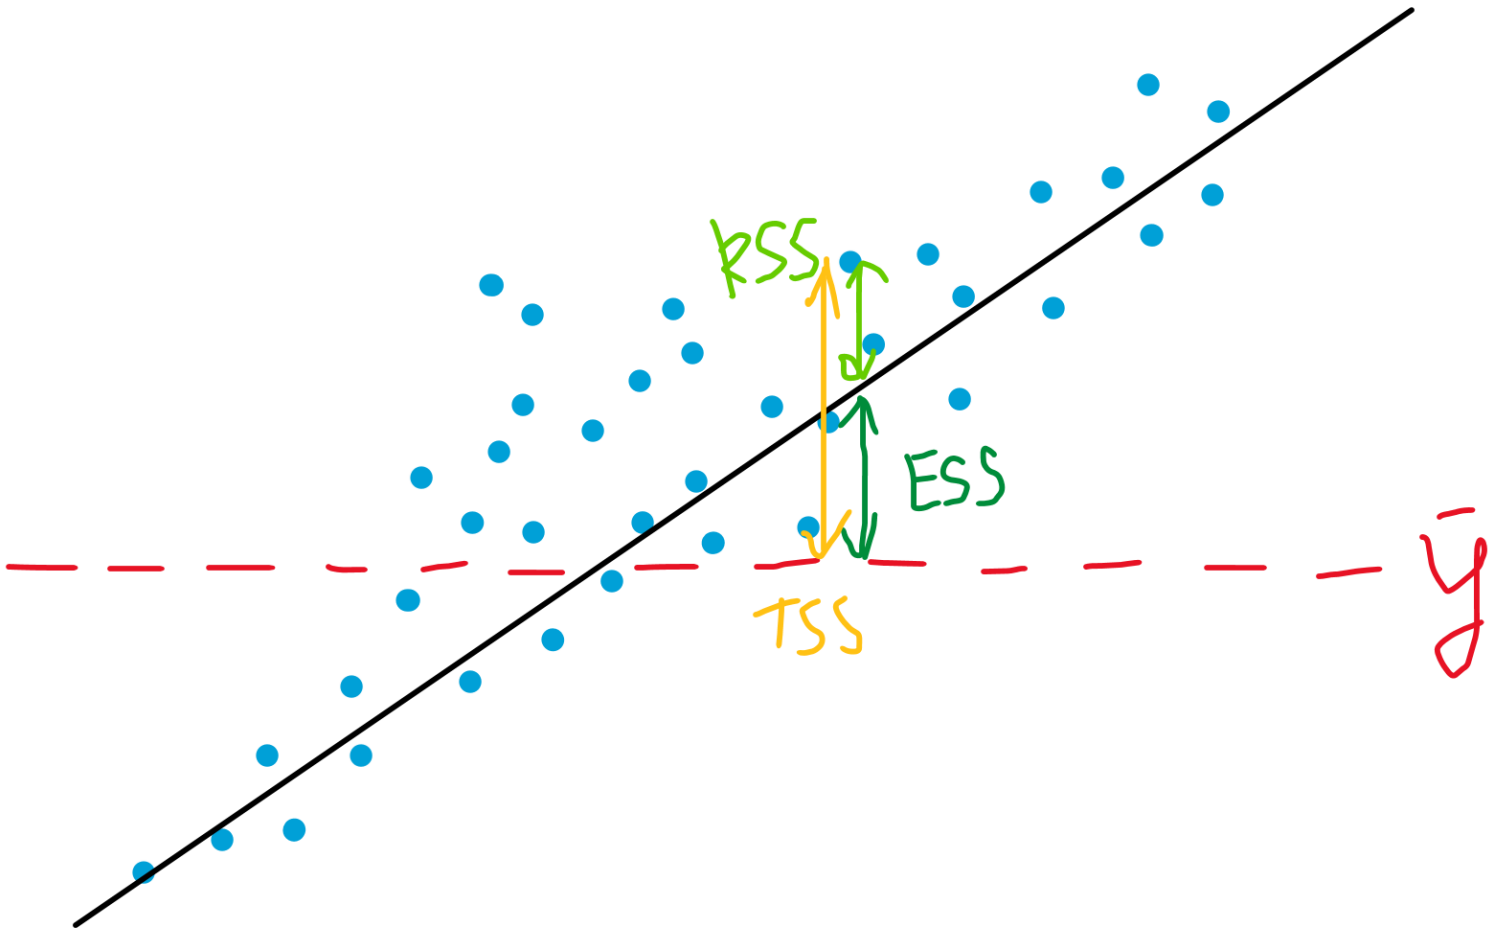
Суммарная квадратичная ошибка тривиального бейзлайна (просто выборочное среднее Y)

$$ESS = \sum (\hat{y}_i - \bar{y})^2$$

explained

Различие прогнозов полной модели и тривиального бейзлайна

Квадраты остатков



Коэффициент детерминации

$$R^2 = \frac{ESS}{TSS} \quad \in [0, 1]$$

Доля объясненной более сложной моделью ошибки в ошибке тривиального бейзлайна

- С осторожностью стоит использовать R^2 для рассуждений о «качестве» модели. R^2 скорее показывает полноту спецификации;
- R^2, как он есть, также нельзя использовать для сравнения моделей между собой.

Гипотеза о многих параметрах

А модель в целом «адекватная»?
Или её надо полностью поменять?

Идея: чем больше R^2, тем полнее модель. На этом сконструируем наш тест

$$H_0: \theta_i = \theta_j = 0, \; i \neq j$$

$$H_1: \forall \theta_i \neq 0$$

Все коэффициенты модели равны нулю: модель «бесполезная»

Хотя бы один коэффициент в модели отличен от нуля

Если отклоняем H0, то хотя бы один «адекватный» параметр в нашей модели есть. Конкретнее о каждом параметре можно узнать, проведя на нем уже известный нам z-тест или t-тест в зависимости от кол-ва наблюдений

Гипотеза о многих параметрах: F-тест (критерий Фишера)

$$F = \frac{R^2 / (K-1)}{(1-R^2)/(n-K)} \sim F_{K-1,\, n-K}$$

гаусс. ошибки

K - кол-во параметров

$$(K-1)F \xrightarrow[n\to\infty]{as} \chi^2_{K-1}$$

негаусс. ошибки

Скорректированный коэффициент детерминации

$$R^2_{adj} = 1 - \frac{n-1}{n-k}(1-R^2)$$

- Штрафует за добавление дополнительных переменных;
- По скорректированному коэффициенту детерминации можно сравнивать модели между собой

Зачем нужна линейная регрессия?

Задача описания
(как устроен мир?)

Эконометрика

Основное:
интерпретируемость, отсюда идет борьба за предпосылки
Есть «арсенал» для обоснования адекватности полученной модели

VS

Задача предсказания
(что будет дальше?)

Machine Learning

Основное: обобщающая способность, хорошее качество прогноза на новых данных

На стыке:
интерпретируемый ML

Напоминание: условия Г-М:

1. Модель правильно специфицирована;
2. Объясняющие переменные линейно независимы;
3. Ошибки независимы друг от друга;
4. Дисперсия ошибок одинакова;
5. Ошибки не зависят от наблюдений;
6. Мат. ожидание ошибок равно нулю.

Зачем требовать выполнения?



Условия Гаусса
- Маркова



Оценки параметров являются **BLUE**

Проверка Гауссовости ошибок

- На самом деле, не является одним из условий Г-М, но зачастую дополнительно вводится для корректного использования известных нам стат. тестов на малых выборках

Критерий Колмогорова-Смирнова
Критерий Крамера-Мизеса
Критерий Андерсона-Дарлинга

Критерий Жарка-Бера (в statsmodels называется Omnibus)
Критерий Шапиро-Уилка

QQ-plot
…

Проверка Гауссовости ошибок

Что, если ошибки не гауссовые?

- Проверить остальные условия Г-М, отработать с ними, вернуться к проверке гауссовости;
- Если есть предположение о том, что ошибки принадлежат другому распределению – попробовать оценить ММП с другим распределением ошибок;
- Если в целом Вам кажется, что все сделано правильно и данных много (настолько, что включается ЦПТ) – работать с тем, что есть

Линейная независимость

Мультиколлинеарность – наличие линейной зависимости между регрессорами



Полная

Строгая (идеальная линейная зависимость)

Неполная

Нестрогая (примерная линейная зависимость)

Линейная независимость

Как проверить?

- Проверьте, что Вы не попались в ловушку дамми-переменных!
  Например: в модели нет одновременно двух бинарных переменных, отвечающих за женский и мужской пол
- Постройте корреляционную матрицу
  Эмпирическое правило: если есть модули корреляции больше 0.8, то проблема нестрогой мультиколлинеарности есть
- Аналог: посмотрите на определитель матрицы $X^T X$
  Если он близок к нулю, то проблема нестрогой мультиколлинеарности есть

Линейная независимость

Как еще проверить?

VIF (Variance Inflation Factor) – коэффициент вздутия дисперсии

$$VIF_j = \frac{1}{1 - R_j^2}$$

- Выбираем объясняющую переменную;
- Строим регрессию для этой переменной, где она сама выступит зависимой, а все остальные переменные – независимыми;
- Считаем R^2 получившейся регрессии (он и используется в формуле выше)

Эмпирическое правило:

VIF = 1 – отсутствие мультиколлинеарности
1 < VIF < 5 – умеренная мультиколлинеарность
5 < VIF < 10 – высокая мультиколлинеарность
VIF > 10 – критическая мультиколлинеарность

Линейная независимость

Как побороться с линейной зависимостью?

1. Feature engineering
   - Удалить одну из коррелирующих переменных (обычно не очень хорошо);
   - Изменить спецификацию на основе здравого смысла, feature importance и тд…
   - Создать новые признаки из старых, понизив размерность (PCA)

2. Регуляризация
   - LASSO, Ridge, ElasticNet
   - Однако, быть осторожными, регуляризация делает оценки смещенными!

Метод главных компонент

Principal Components Analysis (PCA)

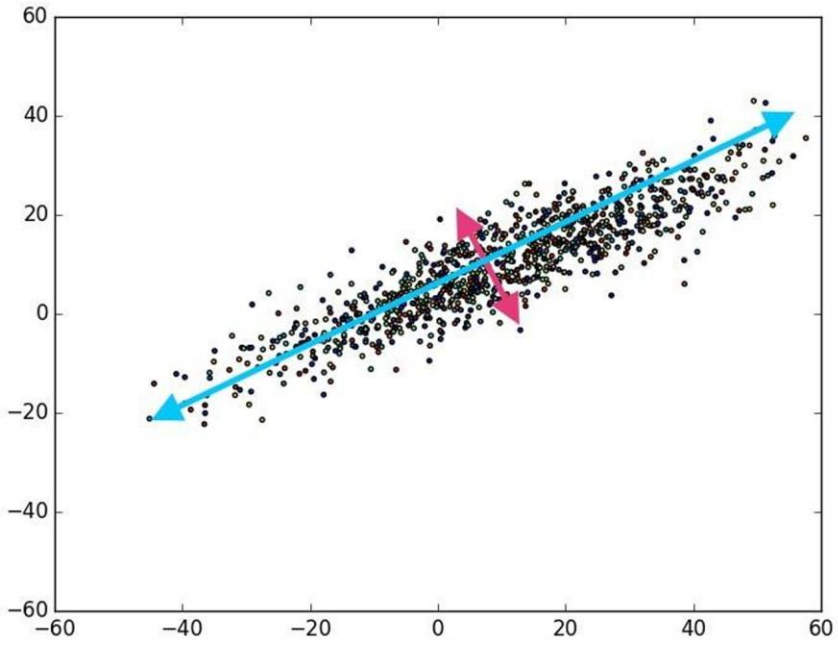
Алгоритм:

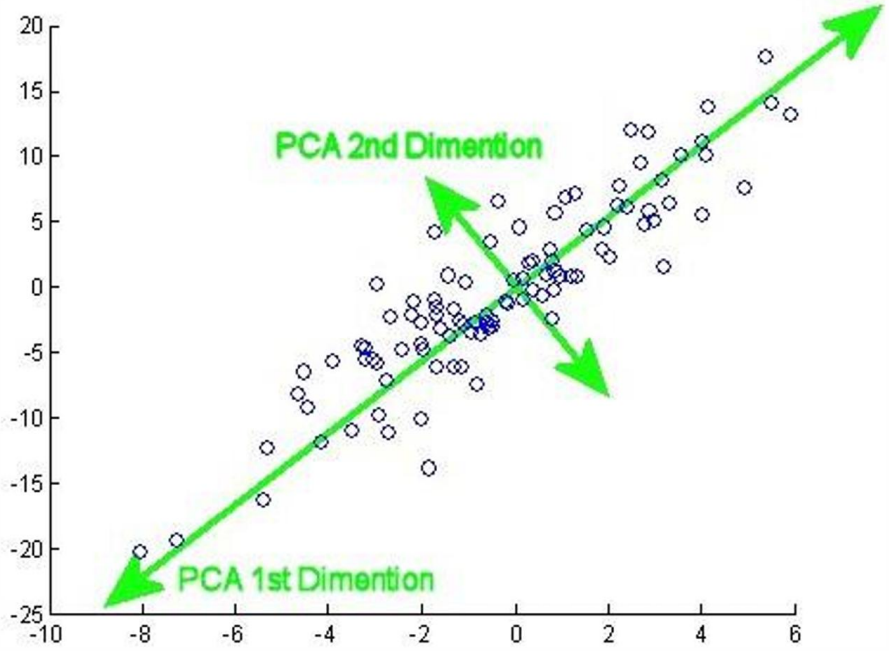
1. Исходные данные нормализуются;

2. Вычисляются собственные векторы и собственные значения матрицы ковариации данных. Эти векторы указывают направления, вдоль которых данные варьируются наиболее сильно;

3. Данные проецируются на несколько первых главных компонент. Выбор количества компонент определяется долей объяснённой дисперсии, которую они покрывают.

Метод главных компонент





Ищем такое направление, после проекции на которое, мы сохраним максимальное количество информации (дисперсии)

Метод главных компонент

- Матричная запись:

$$Z = XW^T$$

Z – матрица главных компонент

- j-й столбец W — коэффициенты при исходных признаках для вычисления нового j-го признака

$$\begin{cases} \sum w_j^T X^T X w_j \to \max\limits_{w} \\ w^T w = 1 \end{cases}$$

Новые признаки после PCA являются линейной комбинацией из старых признаков

Метод главных компонент

Пример: из 21й сенсорной характеристики в 8

Table.1 The results of common factor analysis

	Factor1	Factor2	Factor3	Factor4	Factor5	Factor6	Factor7	Factor8
Color intensity								
Odor intensity								
Taste intensity						0.567		
Foreign tastes		-0.709						
Crystallization								0.427
Florality					0.932			
Fruitiness			0.963					
Berry			0.604					
Herbivory								
Woodiness	0.438							
Spice	0.620							
Wax								0.679
Artificial sugar		-0.567						
Sweetness						0.678		
Bitterness	0.464			0.458				
Sourness							0.438	
Peppercorn				0.894				
Aftertaste	0.653					0.466		
Honey plant		0.495						
Tartness	0.764							
Astringency	0.530							

1. Tartness
2. Absence of extraneous odors and components
3. Fruit and berry flavor
4. Peppercorn (the tickling sensation in the throat after the honey tasting)
5. Florality
6. Intensity of sweet flavor
7. Sourness
8. Sensation of taste, odor, or texture of the wax.

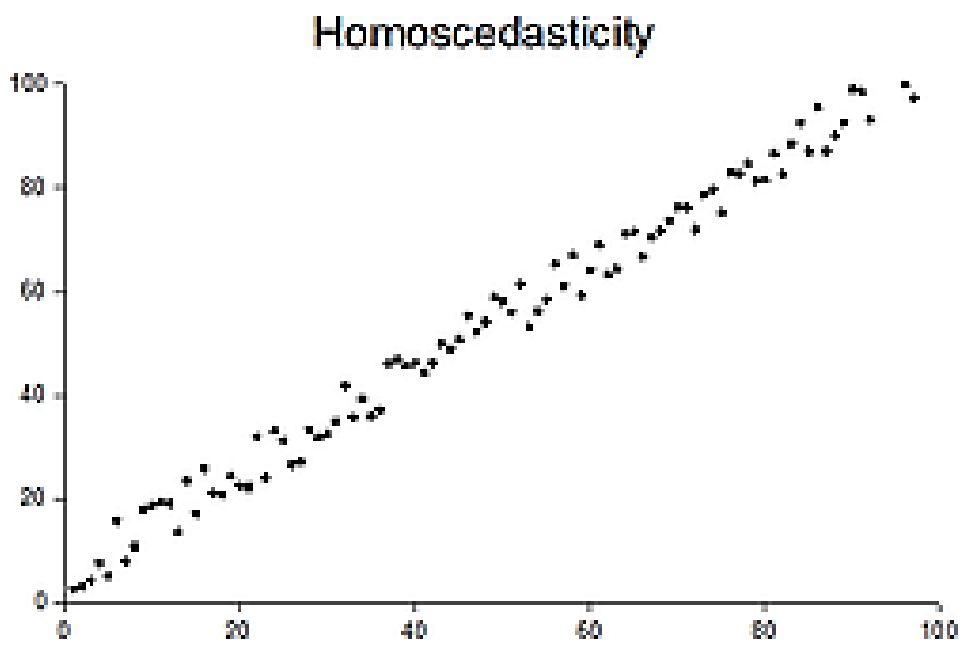


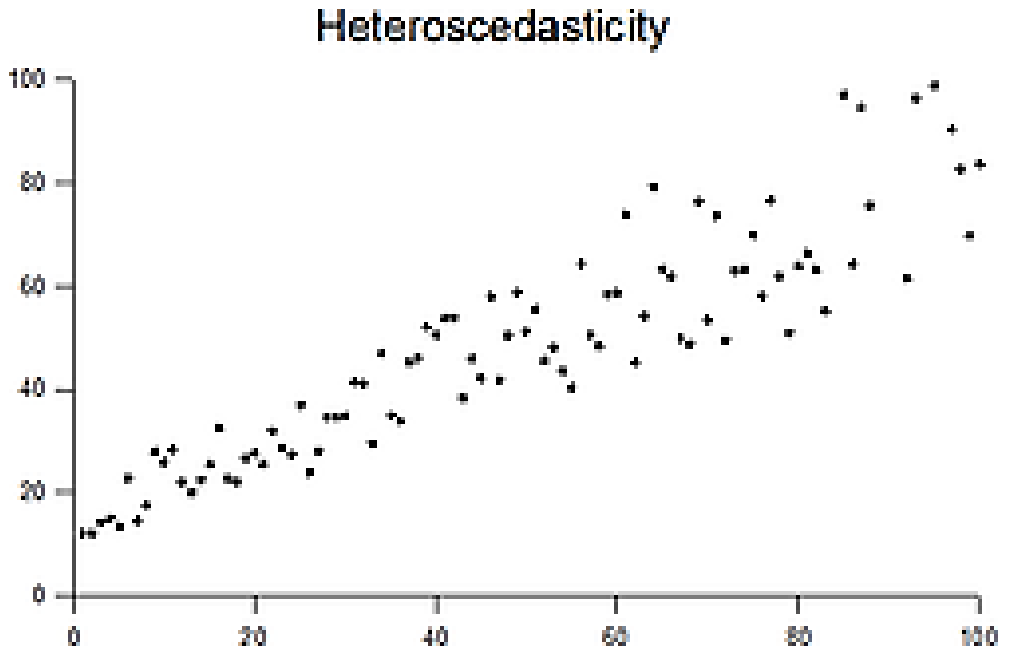
Источник:

Zaripova J., Chuprianova K. C., Polyakova I., Semenova D., Kulikova S. The impact of sensory characteristics on the willingness to pay for honey. *2023.*

Гомоскедастичность

Проблема: дисперсия ошибок непостоянна/по главной диагонали ковариационной матрицы ошибок находятся разные числа

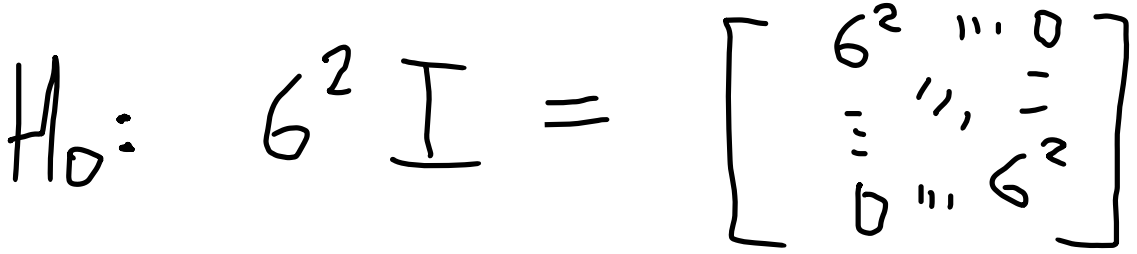




Источник: https://en.wikipedia.org/wiki/Homoscedasticity_and_heteroscedasticity

Гомоскедастичность

Проблема: дисперсия ошибок непостоянна/по главной диагонали ковариационной матрицы ошибок находятся разные числа



Проверять равенство всех дисперсий в ковариационной матрице не вариант, никогда не хватит данных

Как тогда проверить?

Гомоскедастичность

Критерий Гольдфельда-Куандта

Алгоритм:

Предпосылка: $\sigma^2 \sim$ признак

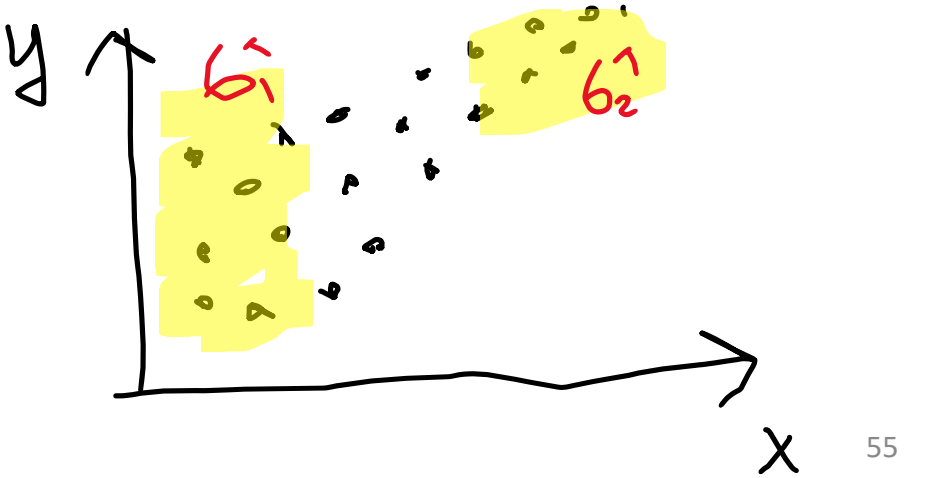
1. Сортируем данные по x (выбранный признак);
2. Из середины ряда убираем d наблюдений;
3. Строим линейную регрессию в двух оставшихся крайних группах;
4. Сравниваем суммы квадратов остатков

$$\hat{\sigma}^2 = \sum \hat{\varepsilon}_i^2 = \sum (y_i - (X\theta)_i)^2$$

$$H_0: \sigma_1^2 = \sigma_2^2$$

$$H_1: \sigma_1^2 \neq \sigma_2^2$$

$$T = \frac{\hat{\sigma}_1^2}{\hat{\sigma}_2^2} \sim F(n_1 - k_1; n_2 - k_2)$$



Гомоскедастичность

Критерий Бреуша-Пагана

Предпосылка: дисперсия остатков зависит от совокупности факторов

Алгоритм:

1. Строим неограниченную регрессию, считаем ее квадраты остатков;
2. Строим ограниченную регрессию на квадраты остатков с p признаков;
3. Считаем RSS ограниченной модели.

$$T = \frac{RSS_R}{2} \sim \chi^2_p$$

Гомоскедастичность

Критерий Уайта

Предпосылка: дисперсия остатков зависит от совокупности факторов

$H_0 = \lambda_1 = \ldots = \lambda_m = 0$ гомоск.

$H_1 = \exists\, \lambda_i \neq 0$ гетероск.

Алгоритм:

$$T = n \cdot R^2_{вспом.} \sim \chi^2_m$$

1. Строим неограниченную регрессию, считаем ее квадраты остатков;
2. Строим регрессию на квадраты остатков, где регрессорами выступают исходные признаки, их квадраты и попарные произведения;
3. Считаем RSS вспомогательной модели.

Гомоскедастичность

Что делать, если все-таки обнаружили гетероскедастичность?

1. Преобразовать зависимую переменную (часто: логарифмирование, извлечение квадратного корня);

2. Использовать робастные ошибки (ошибки в форме Уайта): оставляем несмещенные оценки МНК, но изменяем формулы расчета стандартных ошибок с учетом гетероскедастичности. Данный перерасчет ошибок рекомендуют ***использовать почти всегда***;

3. Использовать взвешенный МНК: предполагаем, как именно меняется дисперсия. Присваиваем каждому наблюдению вес, обратно пропорциональный его дисперсии;

4. Изменить спецификацию модели: добавить новые признаки, полиномиальные признаки.

Гомоскедастичность

Робастные ошибки (ошибки в форме Уайта)

Являются состоятельными при гетероскедастичности

Гомоскедастичность: $var(\hat{\theta}) = \hat{\sigma}^2 (X^T X)^{-1}$, где $\hat{\sigma}^2 = \frac{RSS}{n-k}$

Гетероскедастичность (при отсутствии автокорреляции): $var(\hat{\theta}) = (X^T X)^{-1} \left(\sum_{t=1}^{n} e_t^2 x_t x_t^T \right) (X^T X)^{-1}$

Вместо неизвестных дисперсий – используем оцененные квадраты ошибок

Стандартные ошибки в форме Уайта никак не влияют на расчет самих оценок модели, однако позволяют скорректировать доверительные интервалы и значимость коэффициентов

Автокорреляция

Проблема: ошибки разных наблюдений связаны между собой / ошибка одного наблюдения «тянет» за собой ошибку другого

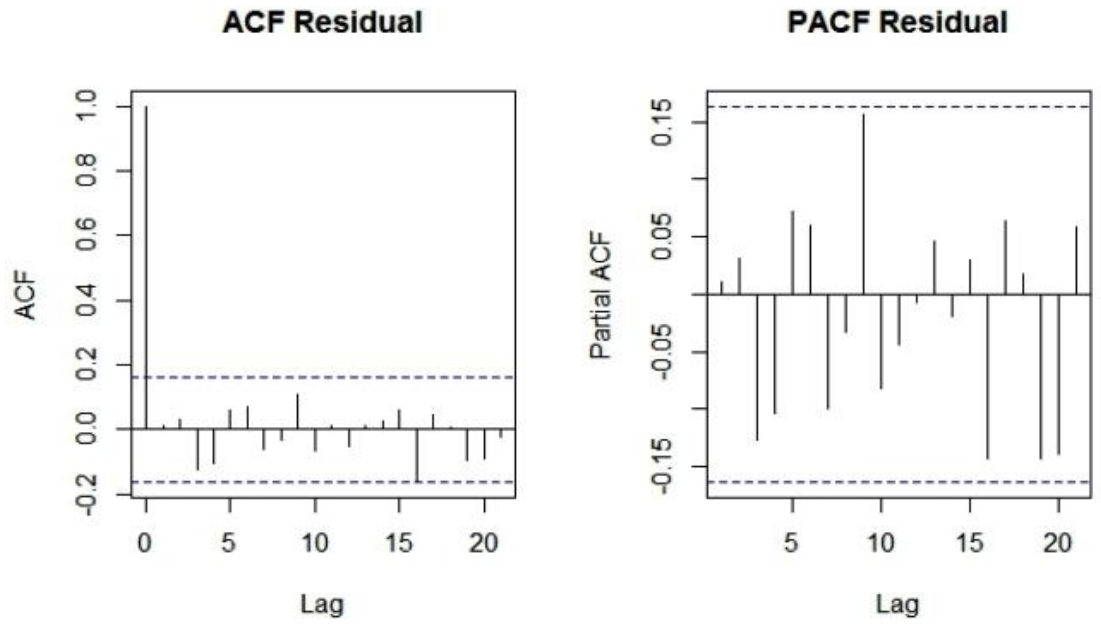
$$Cov(\varepsilon_i, \varepsilon_j) \neq 0 \qquad i \neq j$$

Автокорреляция, гетероскедастичность и эндогенность часто ходят «вместе», возможно, если исправите что-то одно (скорее всего, речь пойдет про эндогенность), то есть приличный шанс, что остальное «сгладится»

Автокорреляция

Как увидеть?

1. Нарисовать график остатков – если похоже на случайный шум, то автокорреляции нет. Если есть «паттерн» - скорее всего, есть. Более того, обычно автокорреляция автоматически возникает при наличии гетероскедастичности;
2. Построить ACF (график автокорреляции) и PCF (график частичной автокорреляции), посмотреть, есть ли большие корреляции по модулю (которые превосходят дов. интервал для нуля)



Автокорреляция

Критерий Дарбина-Уотсона

Предпосылка: $\varepsilon_t = \rho \varepsilon_{t-1} + \mu_t$, $\mu_t \sim iid\ N(0, \sigma^2)$

$H_0: \rho = 0$ Автокорреляции нет

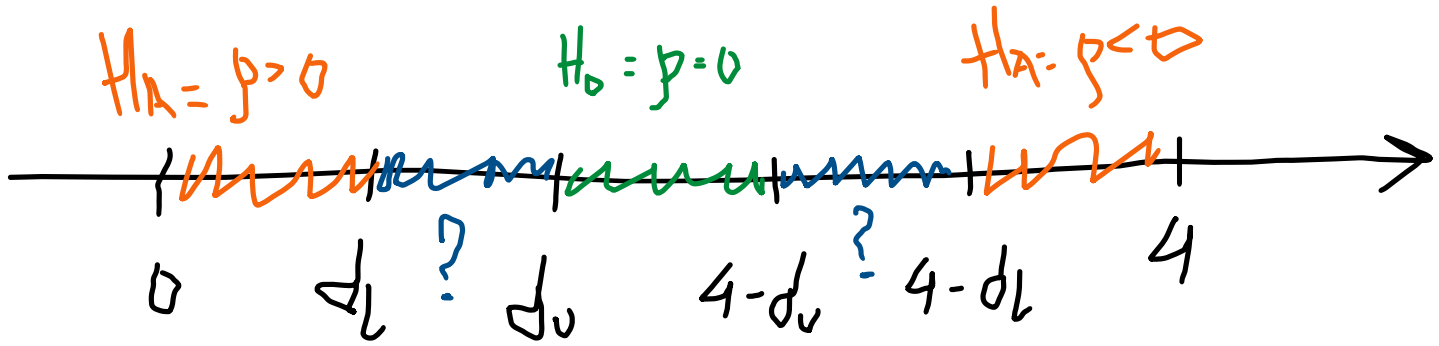
$H_A: \rho \neq 0$ Автокорреляция есть

$$T = \frac{\sum_{t=2}^{n} (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=1}^{n} \hat{\varepsilon}_t^2} \in [0; 4]$$

Автокорреляция

Критерий Дарбина-Уотсона

d_L, d_U – Квантили распределения Дарбина-Уотсона



Тест Дарбина-Уотсона не совсем классический в плане принятия решения, так как есть «зоны неопределенности»

Подробнее:

1. https://en.wikipedia.org/wiki/Durbin%E2%80%93Watson_statistic
2. Durbin, J.; Watson, G. S. (1971). "Testing for serial correlation in least squares regression.III". *Biometrika*. **58** (1): 1-19. doi:10.2307/2334313. JSTOR 2334313

Автокорреляция

Критерий Льюинга-Бокса

Рассчитаем корреляции вида: $\rho_p = corr(\varepsilon_{t+p}, \varepsilon_t)$

$H_0 = \rho_1 = \rho_2 = \dots = \rho_p = 0$

Автокорреляции нет

$H_A: \exists \rho_j \neq 0$

Автокорреляция есть

$$T = n(n+2)\sum_{j=1}^{p} \frac{\hat{\rho}_j^2}{n-j} \overset{as}{\sim} \chi^2_p$$

Гомоскедастичность и автокорреляция

Робастные ошибки (ошибки в форме Ньюи-Уэста)

Являются состоятельными при гетероскедастичности и автокорреляции

Гомоскедастичность: $\widehat{var}(\hat{\theta}) = \hat{\sigma}^2 (X^T X)^{-1}$, где $\hat{\sigma}^2 = \frac{RSS}{n-k}$

Гетероскедастичность (с автокорреляцией):

$$\widehat{var}(\hat{\theta}) = (X^T X)^{-1} \left(\sum_{t=1}^{n} e_t^2 x_t x_t^T + \sum_{j=1}^{L} \sum_{t=j+1}^{n} w_j e_t e_{t-j} \left(x_t x_{t-j}^T + x_{t-j} x_j^T \right) \right) (X^T X)^{-1}$$

Кроме главной диагонали в ковариационной матрице ошибок требуется оценить еще побочные элементы (есть нюансы с подбором параметров)

Подробнее: https://w.wiki/Fp6s

Эндогенность

Одна или несколько объясняющих переменных (X) скоррелированы с ошибкой (ε) в модели регрессии

Причины:

1. Пропущенная переменная: переменная, скоррелированная с пропущенной «вбирает» в себя эффект пропущенной;

2. Одновременность: эффект смещен, так как влияние двух переменных взаимное;

3. Ошибки измерения: переменная, измеренная с ошибкой, содержит в себе ошибку и оказывается скоррелированной с остатками (более того, чаще всего коэффициент при переменной с ошибкой стремится к нулю)

Тест на пропущенную переменную

RESET-тест (тест Рамсея):

Предпосылка:
В модели есть пропущенные переменные, если это так, то «корректировка модели самой себя» даст прирост объясненной дисперсии

Алгоритм:

1. Оцениваем базовую модель, получаем предсказания;
2. Оцениваем модель где помимо стандартных регрессоров будут содержаться степени (до p-1) предсказаний базовой модели;
3. Проверяем гипотезу о том, что все множители перед полиномами предсказаний равны нулю.

$$H_0: \lambda_1 = \dots = \lambda_p = 0$$
$$H_1: \exists \lambda_i \neq 0$$

$$T \sim F_{p, n-k-p}$$

Статистика аналогична F-тесту с моделью с ограничениями и без ограничений

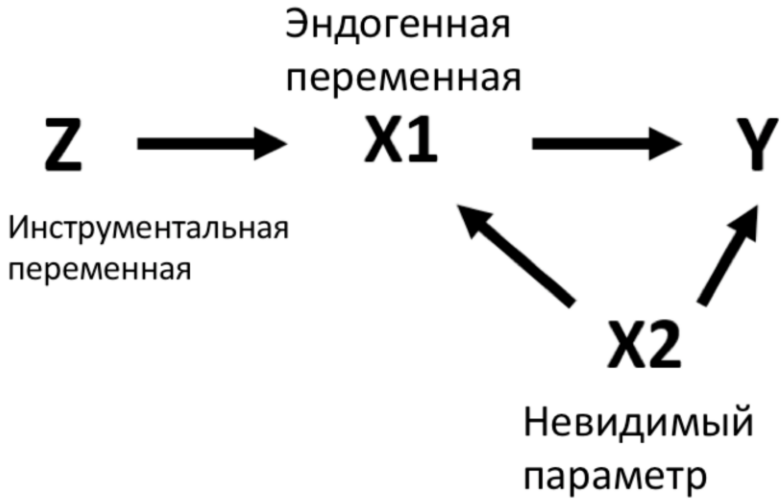
Инструментальные переменные

Как бороться с эндогенностью?

Идея: найдем прокси-переменную/ые для той, которую пропустили

Какими должны быть инструменты:

1. Инструмент экзогенен (не коррелирует с остатком);
2. Инструмент значим (сильно коррелирует с эндогенной переменной)



Инструментальные переменные

Двухшаговый МНК:

Первый шаг: регрессируем эндогенную переменную на экзогенные переменные и инструменты;

Второй шаг: регрессируем зависимую переменную на все экзогенные переменные и предсказанную эндогенную переменную с первого шага.

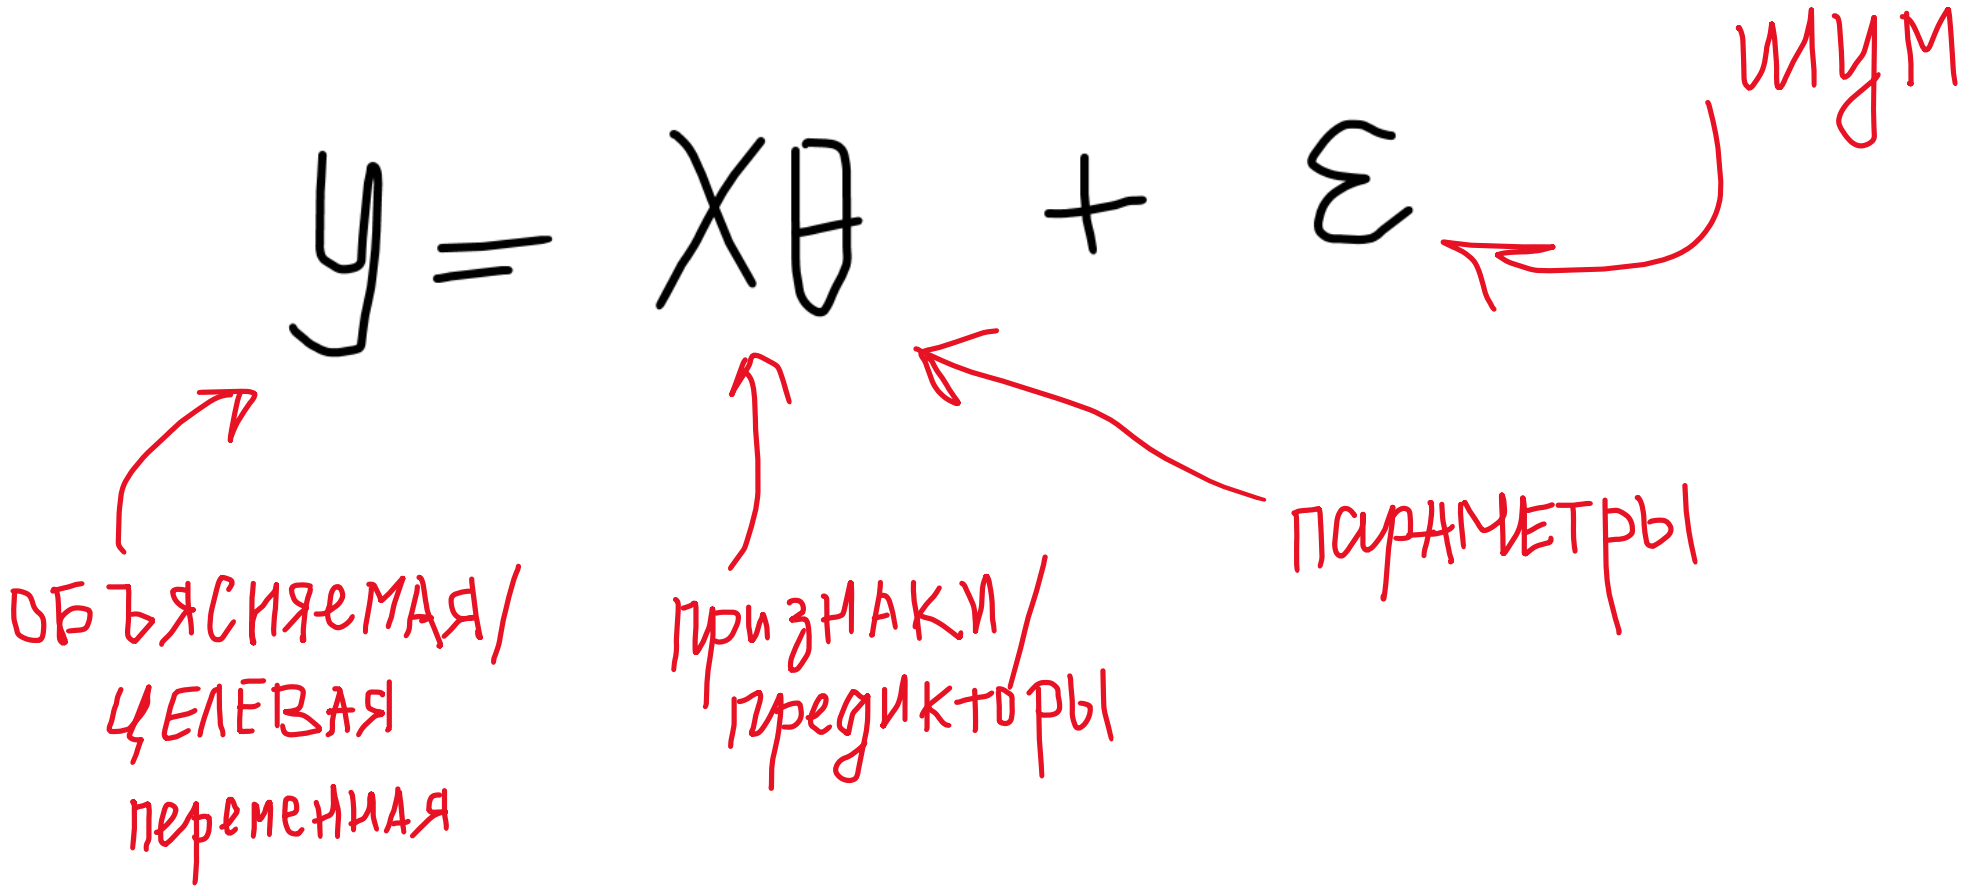
При корректно выбранных инструментах оценки **состоятельны**

Резюме по условиям Г-М

Нарушенное условие	Последствия
Неполная линейная зависимость	Неэффективные оценки, доверительные интервалы шире истинных
Автокорреляция	Неэффективные оценки, доверительные интервалы уже истинных
Гетероскедастичность	Неэффективные оценки, стандартные ошибки оценок смещены, доверительные интервалы ненадежны
Эндогенность	Оценки смещены, неэффективны, несостоятельны

Условие про нулевое мат. ожидание ошибок зачастую автоматически выполнено при включении константы в модель

Напоминание



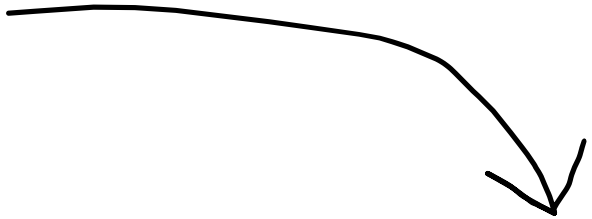
Напоминание

“Линейная регрессия работает всегда, кроме тех случаев, когда она не работает, что происходит почти всегда”

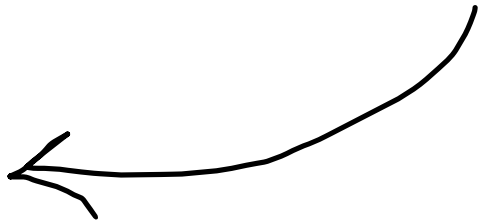
© Комментатор с Youtube

- Выполнены условия Г-М
- Оцениваем МНК
- Получаем **BLUE**

Целевая переменная имеет распределение даже близко, не напоминающее Гауссовое



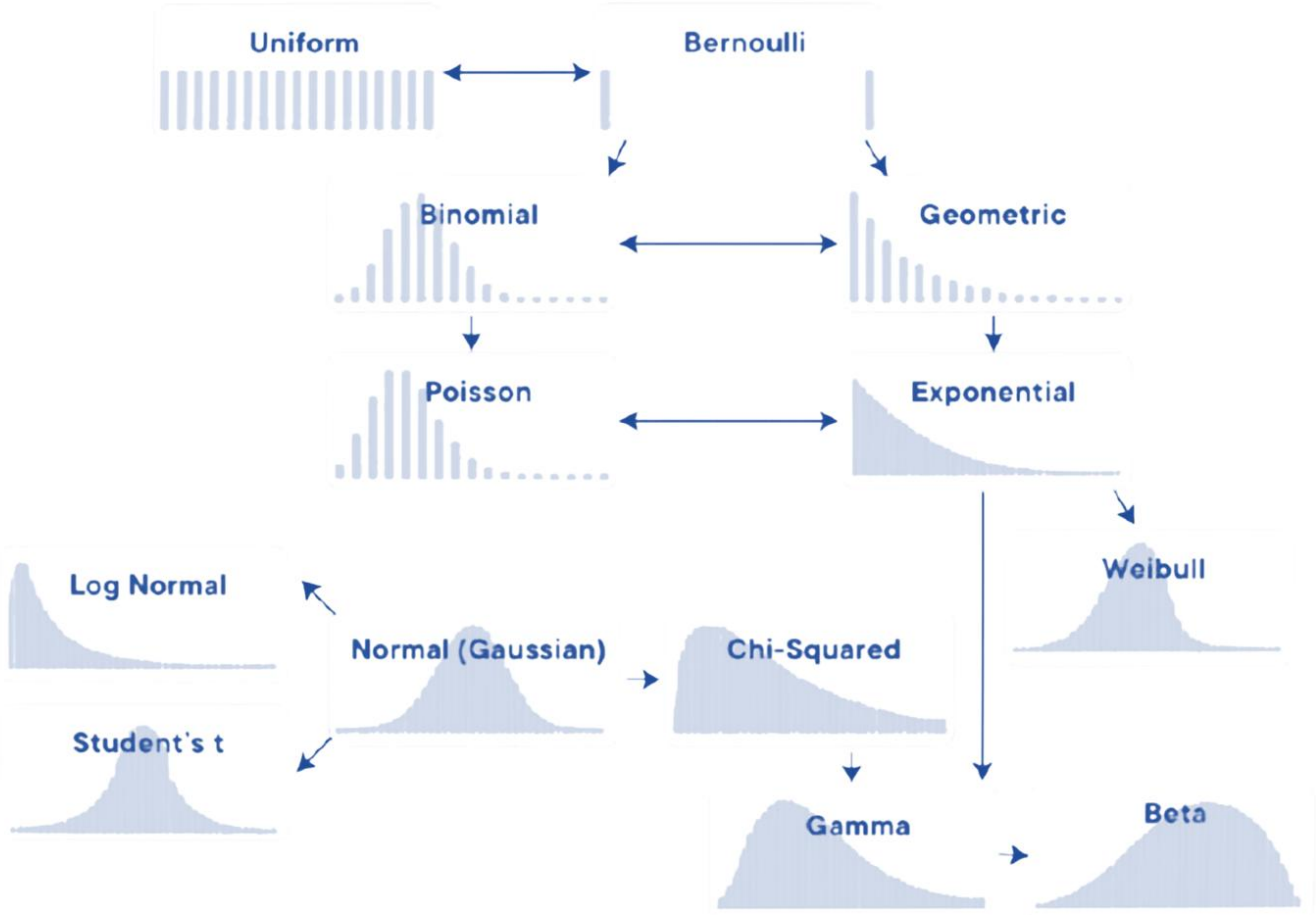
Ошибки автоматически тоже имеют распределение, отличное от нормального



Оценки остаются несмещенными и состоятельными, но перестают быть эффективными

Нельзя быть уверенными в доверительных интервалах и результатах тестов

Целевая переменная имеет распределение даже близко, не напоминающее Гауссовое



Источник: [GLM — Dropbox]

Обобщенные линейные модели

Generalized linear models (GLM)

Идея: введем монотонную и дифференцируемую функцию связи (g)

$$g(y_i) = \theta_0 + \theta_1 x_{i1} + \dots + \theta_k x_{ik}$$

$$\hat{y}_i = g^{-1}(\hat{\theta}_0 + \hat{\theta}_1 x_{i1} + \dots + \hat{\theta}_k x_{ik})$$

Функция связи преобразует распределение целевой переменной так, что :

- Оно принимает значения от $-\infty$ до $+\infty$
- Оно линейно зависит от регрессоров модели

Обобщенные линейные модели

Запишем немного по-другому:

$$y \sim \text{Exponential Family}(\mu, \varphi)$$

здесь вся случайность

$$E(y) = \mu$$

$$g(\mu) = X\theta$$

Или:

$$E(y|X) = \mu = g^{-1}(X\theta)$$

- В модели GLM нет компоненты «случайного шума», так как мы уже зашили его в предположение о распределении переменной;
- В этом смысле постановка 1: ошибки распределены нормально, и постановка 2: целевая переменная распределена нормально, используем функцию связи Identity, - являются эквивалентными

Обобщенные линейные модели

- Оценка GLM позволяет ослабить условия Гаусса-Маркова, а именно отказаться от предпосылки о гомоскедастичности и отсутствии автокорреляции;

- Иначе говоря, ковариационная матрица ошибок может быть любой (естественно, симметричной и положительно определенной, иначе, это не ковариационная матрица)

Обобщенные линейные модели

- Оценка МНК применима, но не гарантирует BLUE;
- GLM зачастую оцениваются с помощью метода максимального правдоподобия;
- Если решение в аналитическом виде для функции правдоподобия недоступно, то используют итеративные методы, в частности IRLS (Iteratively Reweighted Least Squares)

Robust Regression

$$y = X\theta + \varepsilon \qquad \varepsilon \sim Laplace(0, a)$$

Или эквивалентно:

$$y \sim Laplace(\mu, a)$$

$$g = Identity()$$

Функция правдоподобия:

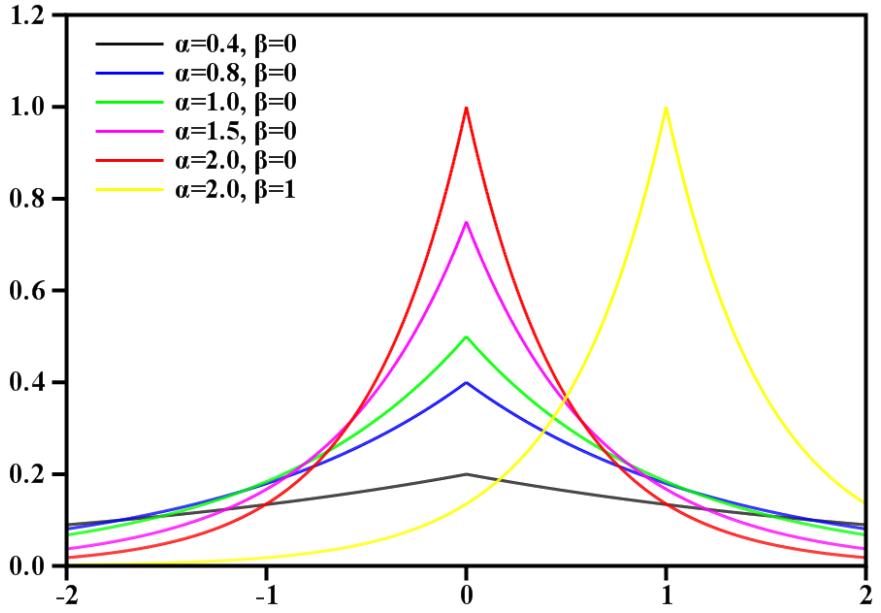
$$L = \left(\frac{a}{2}\right)^n \cdot \exp^{-a \sum |y_i - \theta x_i|}$$

$$\ln L = n \ln \frac{a}{2} - a \sum |y_i - \theta x_i| \to \max_\theta$$

$$\Updownarrow$$

$$\sum |y_i - \theta x_i| \to \min_\theta$$

MAE



$$f(x) = \frac{a}{2} \cdot \exp^{-a|x-\mu|}$$

Robust Regression

$$MAE = \frac{1}{n}\sum |y_i - \hat{y}_i|$$

$$\int |y-\hat{y}| \cdot f(y|x)\,dy \to \min_{\hat{y}}$$

$$\int_{\hat{y}>y} (\hat{y}-y)\cdot f(y|x)\,dy + \int_{\hat{y}<y} (y-\hat{y})\cdot f(y|x)\,dy \to \min_{\hat{y}}$$

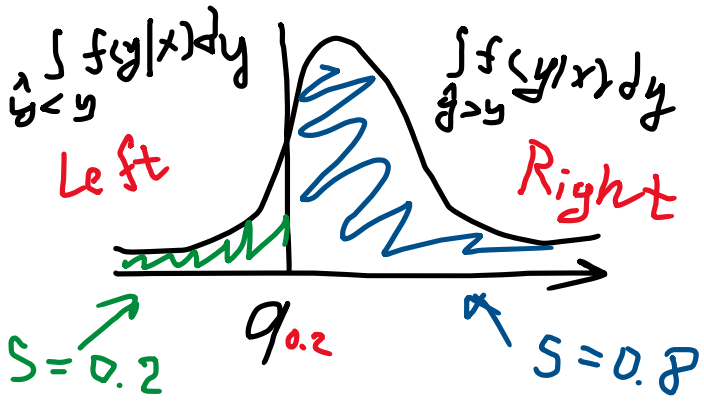
$$\text{FOC}: \frac{d}{d\hat{y}} = \int_{\hat{y}>y} f(y|x)\,dy - \int_{\hat{y}<y} f(y|x)\,dy = 0 \Rightarrow$$

$$\Rightarrow \boxed{\hat{y} = \text{Med}(y|x)}$$

Quantile Regression

Идея: обобщим прошлую концепцию на произвольный квантиль

Пример: хотим оценить квантиль уровня 0.2



Тогда, в финальном результате операций с прошлого слайда, мы бы хотели видеть равенство:

$$\frac{Left}{Right} = \frac{0.2}{0.8} \quad \text{или} \quad Right = 4\,Left$$

В общем виде было бы:

$$\frac{Left}{Right} = \frac{\tau}{1-\tau}$$, где τ - уровень квантили

Quantile Regression

Соответствующая такому выводу функция потерь:

$$\sum \rho_\tau (y_i - \hat{y}_i) \to \min_{\hat{y}}$$

Quantile Loss

$$\rho_\tau(u) = \begin{cases} \tau u, & \text{если } u > 0 \\ (\tau - 1) u, & \text{если } u < 0 \end{cases}$$

$$\hat{y} = q_\tau (y|x)$$

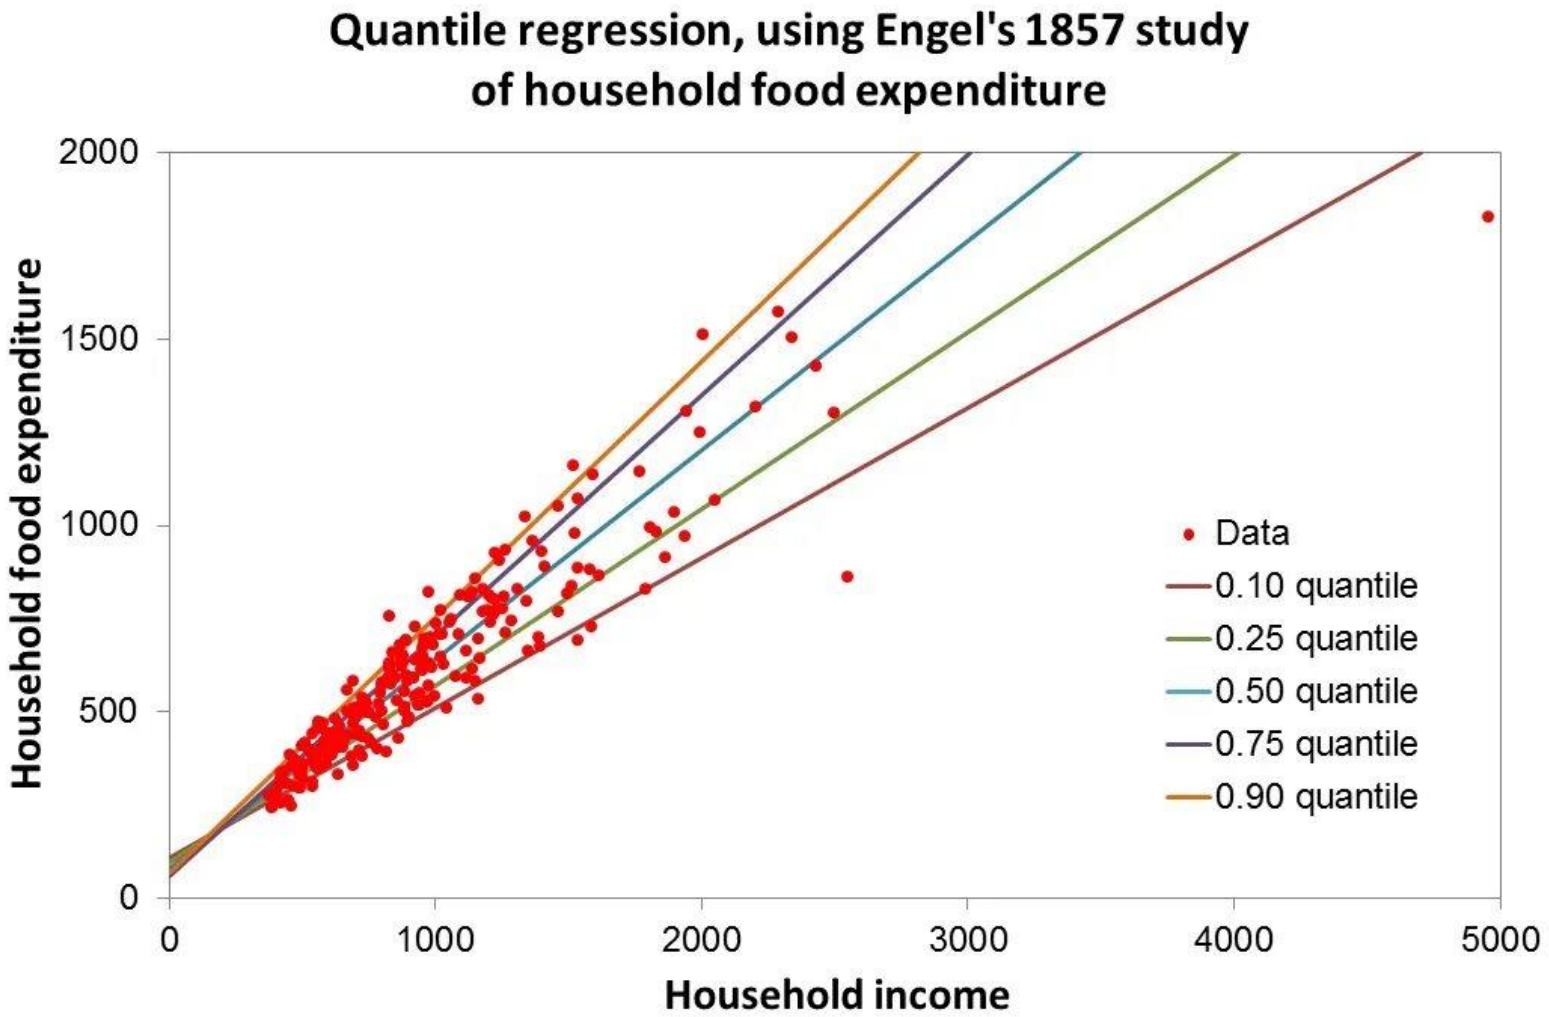
квантиль τ

И исходное распределение ошибок:

$$f(y) = \frac{\tau(1-\tau)}{\sigma} \exp^{-\rho_\tau\left(\frac{y-\mu}{\sigma}\right)}$$

Асимметричная функция Лапласа

Quantile Regression



Logistic Regression

$y_i \sim Bern(p_i)$

$y_i \in \{0, 1\}$ классификация

$$L = p^{\sum y_i} \cdot (1-p)^{n - \sum y_i}$$

$$p_i = P(y_i = 1 \mid X) = g^{-1}(x_i \theta)$$

$p_i(x_i \theta)$

$$L = p_1^{y_1}(1-p_1)^{1-y_1} \cdot \ldots \cdot p_n^{y_n}(1-p_n)^{1-y_n}$$

$$\ln L = \sum_i [y_i \ln p_i + (1-y_i) \ln(1-p_i)] \to \max_\theta$$

$$-\ln L = -\sum_i [y_i \ln p_i + (1-y_i) \ln(1-p_i)] \to \min_\theta$$

LogLoss

Logistic Regression

$$p = \frac{1}{1+\exp^{-x\theta}}$$

sigmoid

$$\ln \frac{p}{1-p} = x\theta$$

При увеличении x на единицу, логарифм отношения шансов увеличивается на θ

$$E[\text{Logloss}|x] = \sum_{k \in y} -y \ln p - (1-y)\ln(1-p)\, P(y=k|x) \to \min_p$$

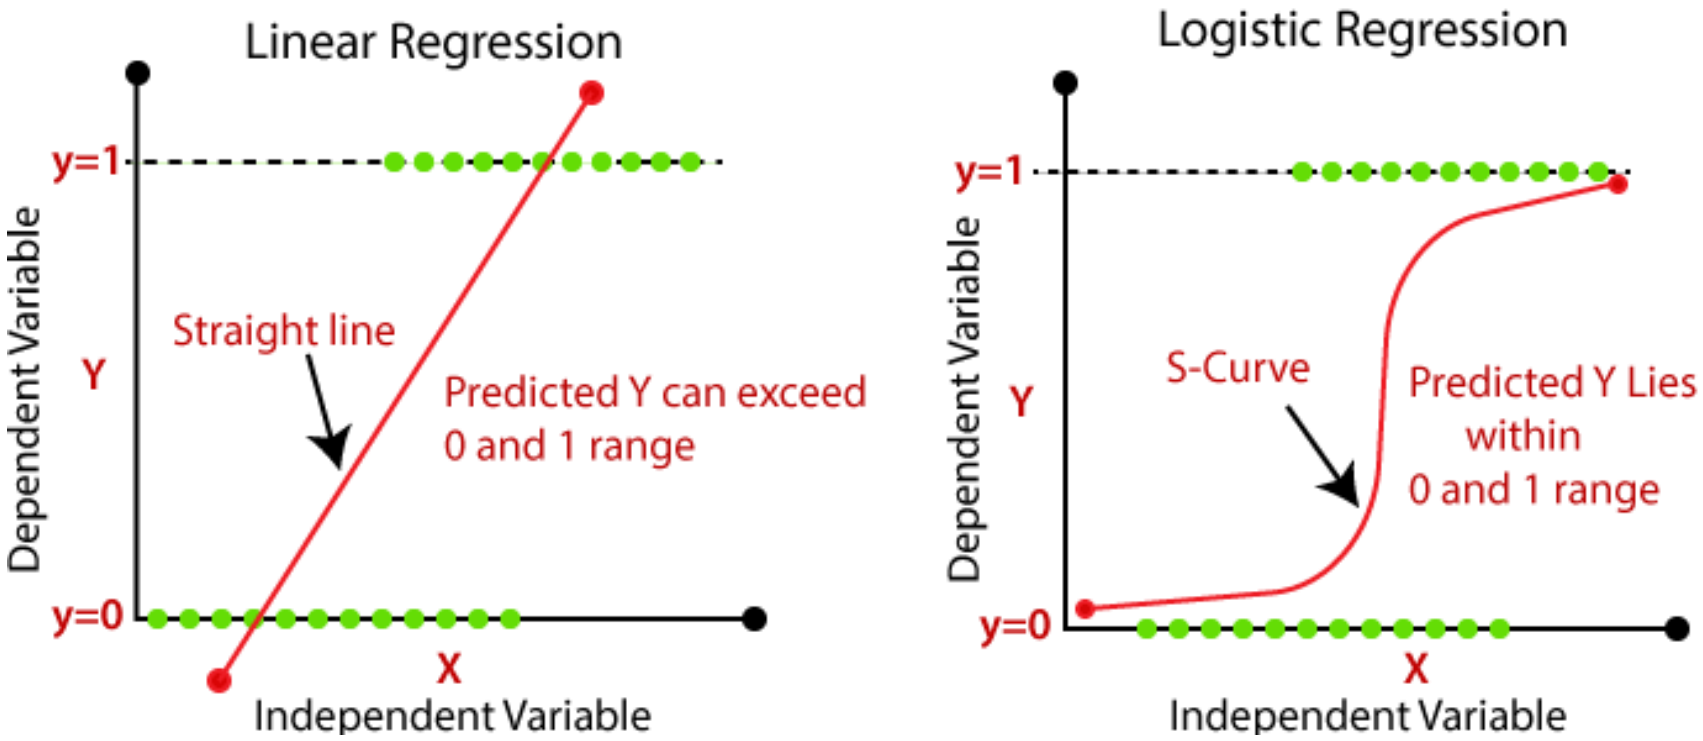
$y = \{0,1\}$ Отбинчим: $P(y=1|x) = e$

$$-(1-e)\cdot \ln(1-p) - e \ln p \to \min_p$$

$$\frac{d}{dp} = \frac{1-e}{1-p} - \frac{e}{p} = 0 \Rightarrow (1-e)p = (1-p)e \Rightarrow \frac{p}{1-p} = \frac{e}{1-e} \Rightarrow p = e$$

$p = P(y=1|x)$

Logistic Regression



Источник: https://github.com/Devinterview-io/logistic-regression-interview-questions

Logistic Regression

Как интерпретировать коэффициенты?

- Отношение шансов (Odds Ratio, OR)

При увеличении X на единицу, шансы события увеличиваются в exp^{θ} раз

- Предельный эффект (Marginal Effect, ME)

При увеличении X на единицу, вероятность $P(Y = 1)$ увеличивается на $\theta * p(X) * (1 - p(X))$

$$\frac{dp}{dX_j} = \theta_j \cdot p(X_j) \cdot (1 - p(X_j))$$

То есть, нужно рассчитать вероятность в «базовом» случае, где все предикторы приняли «базовое» значение, а затем подставить в формулу выше

Logistic Regression

Как интерпретировать коэффициенты?

Пример расчета предельных эффектов:

Пусть есть оцененная логит-модель успеха сдачи экзамена по ТВиМС:

$$P(Y=1) = \frac{1}{1 + exp^{-(-9+0.5*\text{часы подготовки})}}$$

$$ME_{\text{Часы подготовки}} = \frac{dP(Y=1)}{d\text{Часы подготовки}} = \frac{exp^{-(-9+0.5*\text{часы подготовки})}}{(1 + exp^{-(-9+0.5*\text{часы подготовки})})^2} * 0.5$$

Мы уже готовились 15 часов, каков будет прирост по вероятности сдачи от дополнительного часа?

$$ME_{\text{Часы подготовки}(15)} = \frac{dP(Y=1)}{d\text{Часы подготовки}(15)} = \frac{exp^{-(-9+0.5*15)}}{(1 + exp^{-(-9+0.5*15)})^2} * 0.5 = 0.07$$

Дополнительный час принесет нам повышение вероятности сдачи на 7%
Если мы посчитаем предельный эффект при условии, что уже готовились 100 часов, он будет близок к 0

Logistic Regression

Как интерпретировать коэффициенты?

Если у нас много предикторов, то придется фиксировать все остальные, кроме того, для которого считаем предельный эффект, на «базовом уровне»

На практике из-за непостоянства предельного эффекта в разных точках принято считать:

- Предельный эффект для среднего по выборке

В нашем примере вычисляем среднее по выборке время подготовки к зачету , а затем считаем предельный эффект для среднего времени

- Средний предельный эффект

В нашем примере вычисляем предельный эффект для каждого студента, затем считаем среднее значение из предельных эффектов

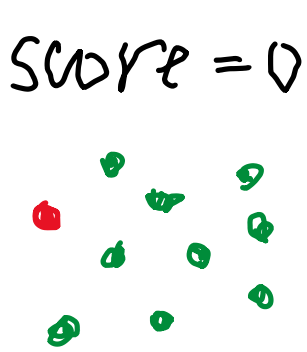
Подробнее: https://books.econ.msu.ru/Introduction-to-Econometrics/chap10/10.2/

Распределения и функции связи

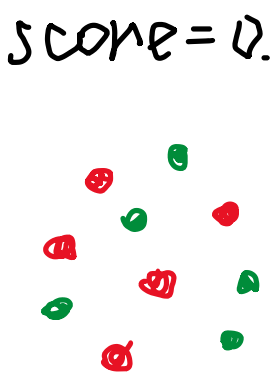
Распределение Y	Функция связи $g(\mu)$	Обратная связь $g^{-1}(\eta)$	Функция потерь в ML	"Классическая" ошибка
Нормальное $N(\mu, \sigma^2)$	μ (identity)	η	**MSE** $\Sigma(y_i - \hat{y}_i)^2$	$\varepsilon \sim N(0, \sigma^2)$
Бернулли $Bern(p)$	**Logit** $\log(p/(1-p))$	**Logistic** $1/(1 + \exp(-\eta))$	**Log Loss** $-\Sigma[y_i \log(p_i) + (1-y_i)\log(1-p_i)]$	Не применимо
Пуассон $Pois(\mu)$	**Log** $\log(\mu)$	**Exp** $\exp(\eta)$	**Poisson Loss** $\Sigma(\mu_i - y_i \log(\mu_i))$	Не применимо
Лапласа $Laplace(\mu, b)$	μ (identity)	η	**MAE** $\Sigma\lvert y_i - \hat{y}_i \rvert$	$\varepsilon \sim Laplace(0, b)$
Асимметричная Лапласа $ALD(\mu, \tau)$	μ (identity)	η	**Quantile Loss** $\Sigma\rho\tau(y_i - \hat{y}_i)$	$\varepsilon \sim AsLaplace(0, \tau)$

Модель предсказывает «вероятность»

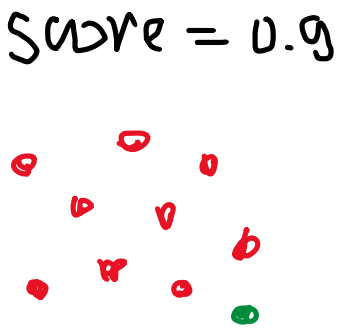
Что это значит?



Среди всех объектов, которым модель назначила скор 0.1, доля красных – это 1/10



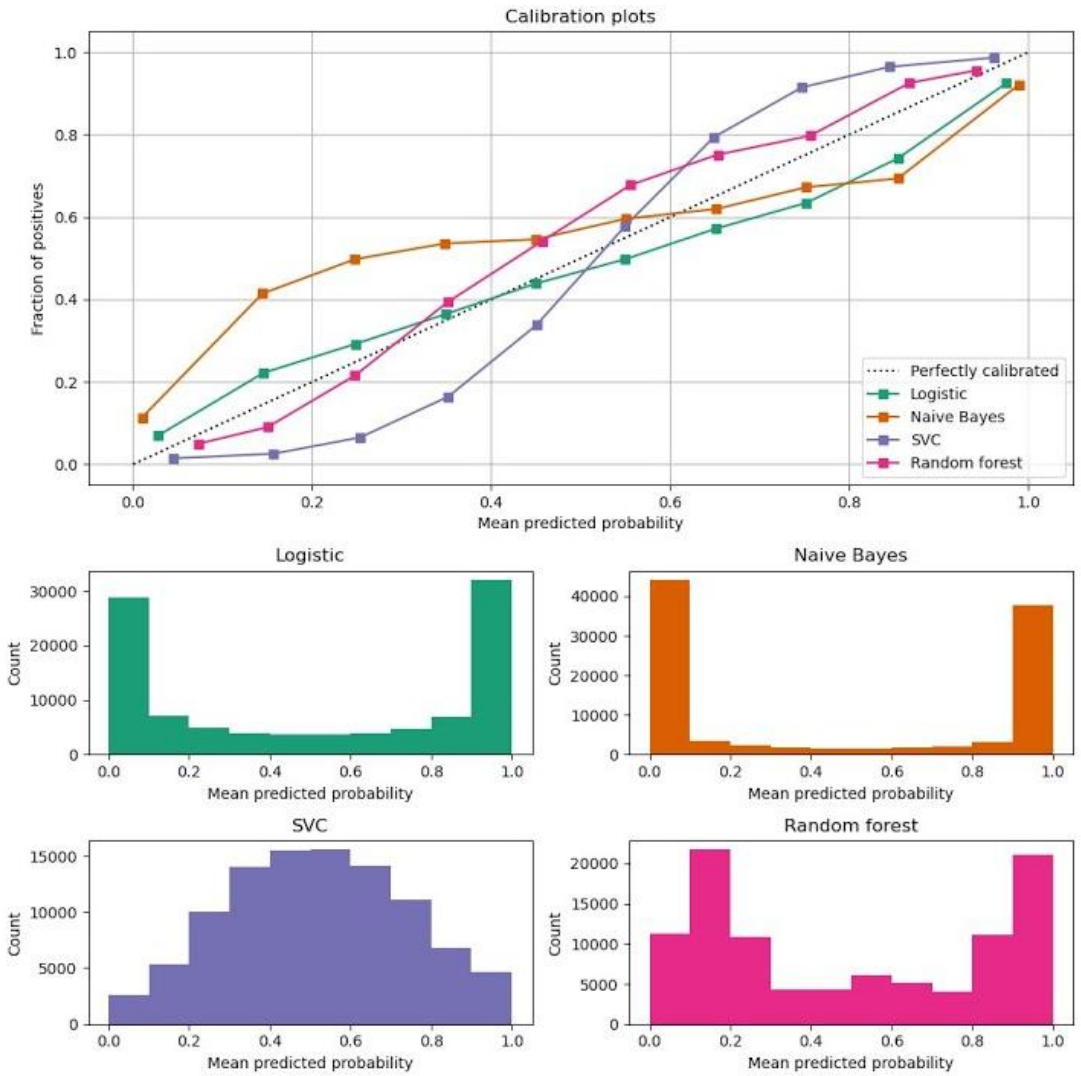
Среди всех объектов, которым модель назначила скор 0.5, доля красных – это 1/2

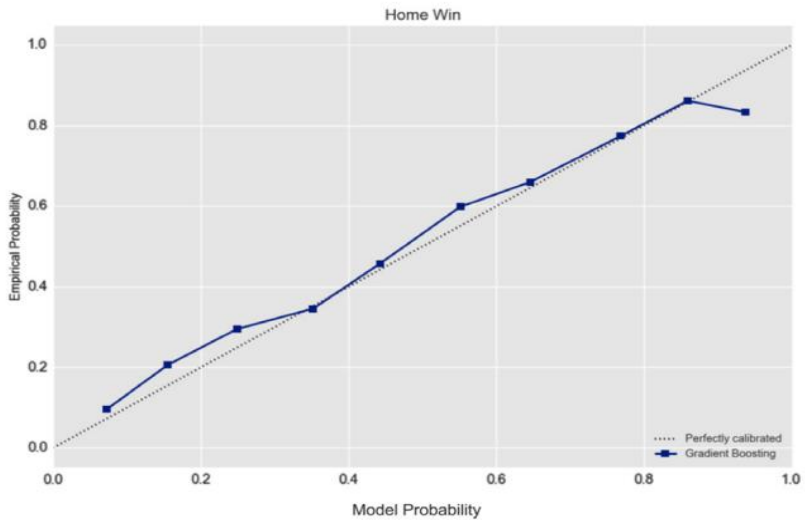


Среди всех объектов, которым модель назначила скор 0.9, доля красных – это 9/10

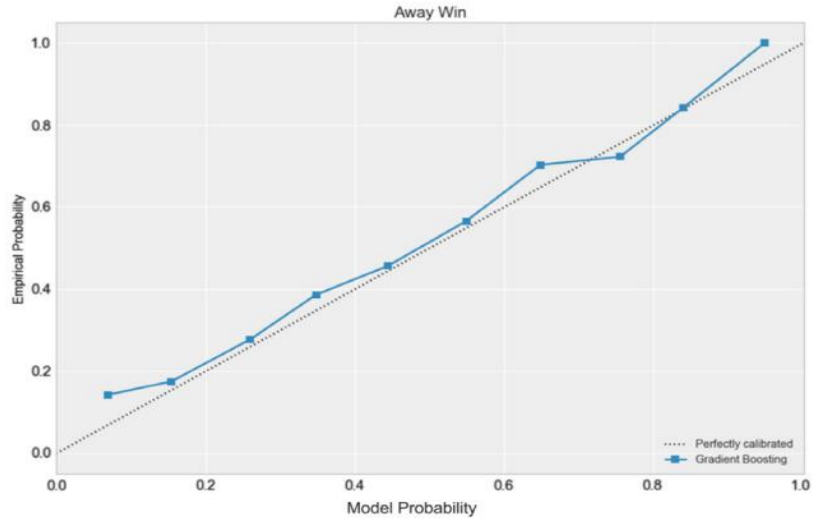
Как доказано на предыдущих слайдах, логит, например, заточен на то, чтобы предсказывать условную вероятность. Однако, меньшинство ML моделей может похвастаться тем же

Калибровочные кривые





(a) Home win.



(b) Away win.

Как калибровать?

Platt Scaling

Идея: построить логит-регрессию на скорах исходной модели (произвольная для бинарной классификации)

$$P_{calib} = \frac{1}{1 + \exp^{-(A \cdot score + B)}}$$

Хорошо работает, если фактическая кривая частот имеет форму, схожую с логистической

Как калибровать?

Isotonic Regression

Идея: “сохраняем порядок” и ищем монотонное преобразование для скоров

Постановка:

Наблюдения: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

$$\begin{cases} \sum_{i=1}^{n} w_i (y_i - f(score_i))^2 \to \min\limits_{f} \\ f(s_1) \le f(s_2) \le \dots \le f(s_n) \end{cases}$$

Хорошо работает со сложными нелинейными искажениями

Подробнее: https://en.wikipedia.org/wiki/Isotonic_regression

Как калибровать?

Isotonic Regression

Алгоритм изотонического восстановления

Идея:

1. Начинаем с тривиального решения: каждая точка — свой сегмент;

2. Объединяем «нарушители»: если два соседних сегмента нарушают монотонность ($\text{mean}(A) > mean(B)$), то объединяем их;

3. Повторяем до тех пор, пока весь ряд не станет монотонным.

На выходе имеем кусочно заданную монотонную функцию

Она является наилучшим среднеквадратичным приближением среди всех монотонных функций

Дополнительно

- Про GLM другими словами: https://education.yandex.ru/handbook/ml/article/obobshyonnye-linejnye-modeli
- Хорошее онлайн-пособие по эконометрике, правда про GLM тут не очень подробно: https://books.econ.msu.ru/Introduction-to-Econometrics/chap05/5.5/
- Если интересна именно эконометрика, то очень советую книгу Вербика: https://id.hse.ru/books/1040796649.html (думаю, есть в открытом доступе где-то)


ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ •