

ФКН

Департамент больших данных и информационного поиска

Москва 2025

Лекция 10
Проверка гипотез +: ранговые критерии

Машинное обучение в цифровом продукте

Полякова И.Ю.

Проверка гипотез: напоминание

$$H_0 \quad \text{vs} \quad H_1$$

- Выдвигаются две гипотезы: нулевая (H_0) и альтернативная (H_1)
- Гипотезы обязаны быть взаимоисключающими!
- Но при этом не обязаны покрывать все «множество допустимых значений»

Проверка гипотез: напоминание

- Для проверки гипотез используется идея доверительных интервалов
- Применяем статистический критерий: правило, по которому на основании выборки принимается решение — отклонить или не отклонить нулевую гипотезу

Какие гипотезы уже умеем проверять?

Из лекций 4-7

- О равенстве средних, долей (одновыборочные, двухвыборочные тесты)
  Z-тест, t-тест

- О равенстве дисперсий
  F-тест

- Критерии согласия (одинаковые распределения)
  KS-тест, DA-тест, KM-тест, Хи-квадрат

- О наличии связи
  Корреляция Пирсона, линейная регрессия, Хи-квадрат

Общая черта: имеют достаточно **жесткие предпосылки** для работы:

Гауссовость, асимптотичность (нужно много данных), предположения Гаусса-Маркова…

Случается разное, например…

- Анализируемые события редки;
- Собирать данные дорого;
- Собирать данные долго

Поэтому хотелось бы сконструировать инструменты, которые:

- Не требуют предположения о гауссовости;
- Не требуют много данных;

- Устойчивы к выбросам;
- Работают с порядковыми данными.

Гипотеза об однородности

$H_0: F_x(x) = F_y(x)$

$H_A: \exists x : F_x(x) \neq F_y(x)$



Гипотеза о сдвиге

$H_0: F_x(x) = F_y(x)$

$H_1: F_x(x) = F_y(x-\mu),\ \mu \neq 0$

Критерий знаков

$X_1, \dots, X_n \overset{iid}{\sim} F_X$

1 выб.

$H_0: med(X) = m_0$

$H_1: med(X) \neq m_0$

$T = \sum_{i=1}^{n} [X_i \leq m] \sim Bin(n, 1/2)$

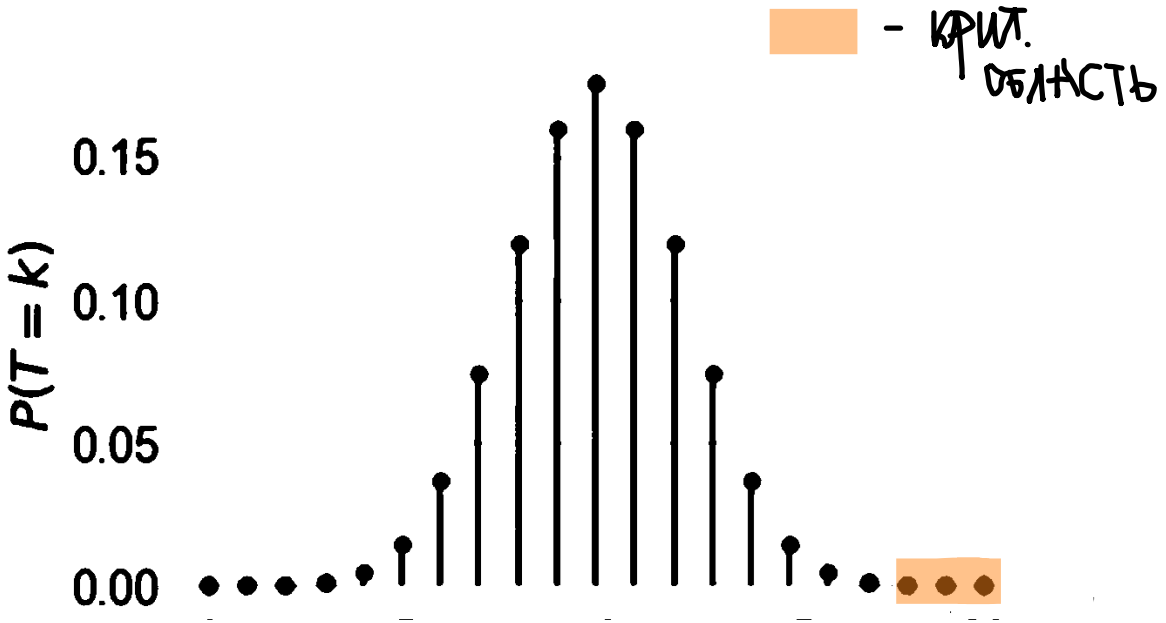
2 выб.

$X_1, \dots, X_n \overset{iid}{\sim} F_X$

$Y_1, \dots, Y_n \overset{iid}{\sim} F_Y$

$H_0: med(X - Y) = 0$

$H_1: med(X - Y) \neq 0$



Используется для связанных выборок!

Критерий знаков

- Потеряли часть информации из-за того, что превращали выборку в нули и единицы;
- Проигнорировали величину эффекта, учли только направление;
- Зато очевидно, каким распределением пользоваться при верной H0;
- Придумаем что-то еще, так как критерий знаков «слабоват»

Ранги

- Упорядочиваем выборку по возрастанию;
- Порядковый номер наблюдения – ранг;

- Одинаковым наблюдениям присваиваем среднее арифметическое их порядковых номеров;
- Есть и другие стратегии, но эта самая популярная

Критерий Вилкоксона

1 выб.

$X_1, \dots, X_n \overset{iid}{\sim} F_X$

$H_0: med(X) = m_0$

$H_1: med(X) \neq m_0$

$$W = \sum_{i=1}^{n} rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

$$W \overset{as}{\sim} N\left(0, \frac{n(n+1)(2n+1)}{6}\right)$$

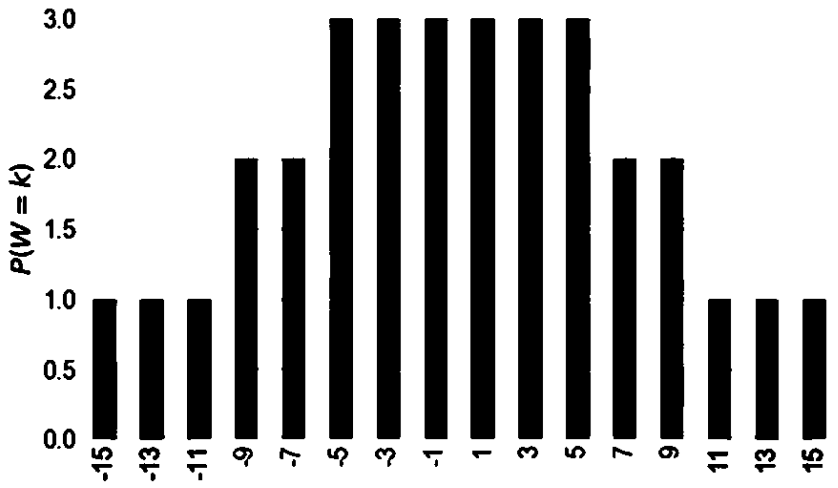
2 выб.

$X_1, \dots, X_n \overset{iid}{\sim} F_X$

$Y_1, \dots, Y_n \overset{iid}{\sim} F_Y$

$H_0: med(X - Y) = 0$

$H_1: med(X - Y) \neq 0$



Используется для связанных выборок!

Критерий Манна-Уитни

$$H_0: F_x(x) = F_y(x)$$

$$H_1: F_x(x) = F_y(x - M), \; M \neq 0$$

Выборки не обязаны быть связанными

- Объединяем обе выборки в один вариационный ряд;
- Считаем сумму рангов наблюдений из первой выборки и из второй;
- Рассчитываем тестовую статистику

$$U = \min(U_x, U_y)$$

$$U_x = nm + \frac{n(n+1)}{2} - R_x$$

$$U_y = nm + \frac{m(m+1)}{2} - R_y$$

Есть табличное распределение + достаточно быстро добиваемся нормальной аппроксимации

Критерий Ансари-Бредли

$$H_0: F_X(x) = F_Y(x)$$

$$H_1: F_X(x) = F_Y(dx),\ d \neq 0$$

- Вычитаем выборочную медиану из каждой выборки;
- Объединяем в единый вариационный ряд

$$A = \sum_{i=1}^{n} \left(\frac{n+m+1}{2} - \left| R_i - \frac{n+m+1}{2} \right| \right)$$

Ранг медианы

Отклонение от ранга медианы

Есть табличное распределение + нормальная аппроксимация

Проверка гипотезы о связи

- Раньше мы это делали с помощью корреляции Пирсона;
- Либо построения линейной регрессии;
- Однако, подобные инструменты ловят только линейную взаимосвязь;
- Более того, не способны работать с порядковыми шкалами, что зачастую бывает очень важно

Корреляция Кендалла

$$\tau_{xy} = 1 - 2P\left((x_2 - x_1)(y_2 - y_1) < 0\right)$$

(x_1, y_1)
(x_2, y_2)

$$\hat{\tau}_{xy} = 1 - \frac{4k}{n(n-1)},$$

k – число несогл. пар: $(x_2 - x_1)(y_2 - y_1) < 0$

или

$$\hat{\tau}_{xy} = \frac{2 \sum_{i<j} \operatorname{sign}\left((R_i - R_j)(S_i - S_j)\right)}{n(n-1)}$$

Ищет монотонные зависимости

Есть табличное распределение + нормальная аппроксимация

$$\tau = \frac{\hat{\tau}_{xy}}{\sqrt{\frac{4n+10}{9n(n-1)}}}$$

Корреляция Спирмена

$$\hat{\rho}_{xy} = \frac{\sum (R_i - \bar{R})(S_i - \bar{S})}{\sum (R_i - \bar{R})^2 (S_i - \bar{S})^2} \in [-1 ; 1]$$

- Так же, как и корреляция Кендалла, ищет монотонные зависимости;
- Является ранговым аналогом корреляции Пирсона

Польза ранговых корреляций

- Зачастую в некоторых доменных задачах критерием качества выступают оценки экспертов (естественно, в ранговой шкале);
- Размечать огромные датасеты с помощью экспертов – дорого и долго;
- Зачастую используют некий набор метрик, который можно описать как «коррелированность с оценками экспертов», где и используются ранговые корреляции

Тексты: GLUE, BERTScore

Картинки: Perceptual Quality Metric, Inception Score, SuperGlue

…

Дополнительно

- Очень-очень много ранговых критериев: https://clck.ru/3QvHmv
- Про экспертные оценки LLM: https://habr.com/ru/articles/852046/
- Конспект про ранговые критерии (чуть подробнее текущих слайдов): https://github.com/XuMuK1/psmo/blob/2024/lectures/Lec7(Rank).pdf


ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ •