ФКН

Департамент больших данных и информационного поиска

Москва 2025

Лекция 12
Байесовский подход

Машинное обучение в цифровом продукте

Полякова И.Ю.

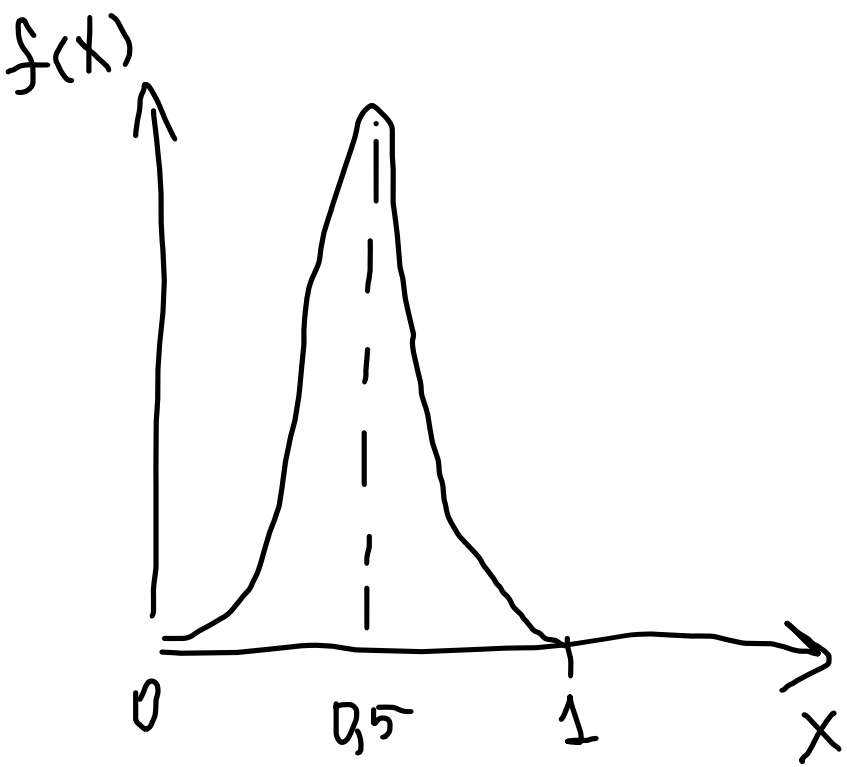
Два типа неопределенности

Алеаторная – возникает из-за случайности

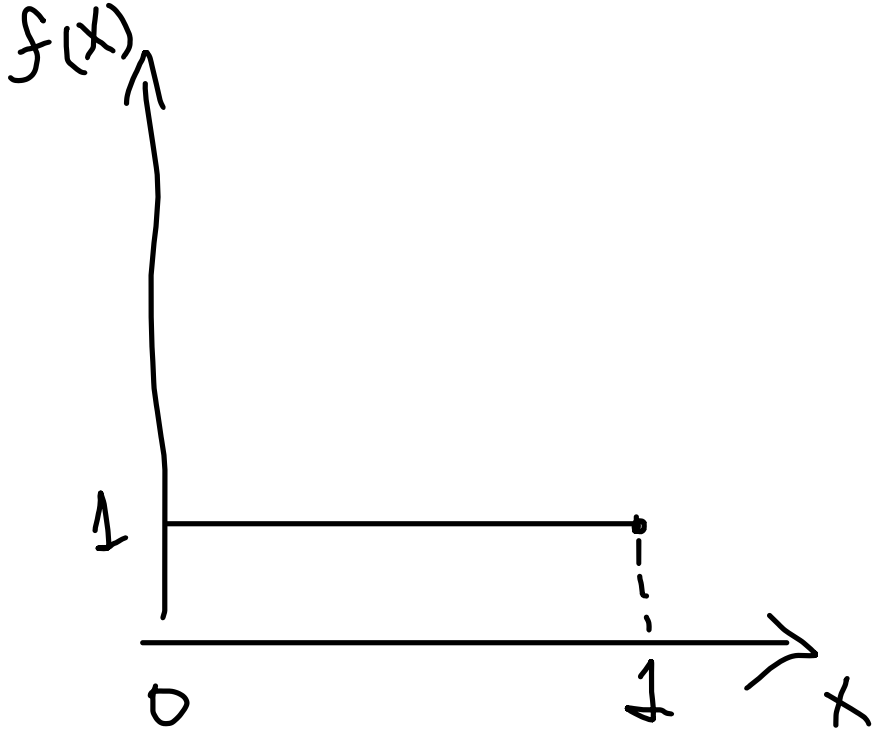
Эпистемическая – возникает из-за недостаточного знания

Цель анализа данных – понизить эпистемическую неопределенность

Два типа неопределенности

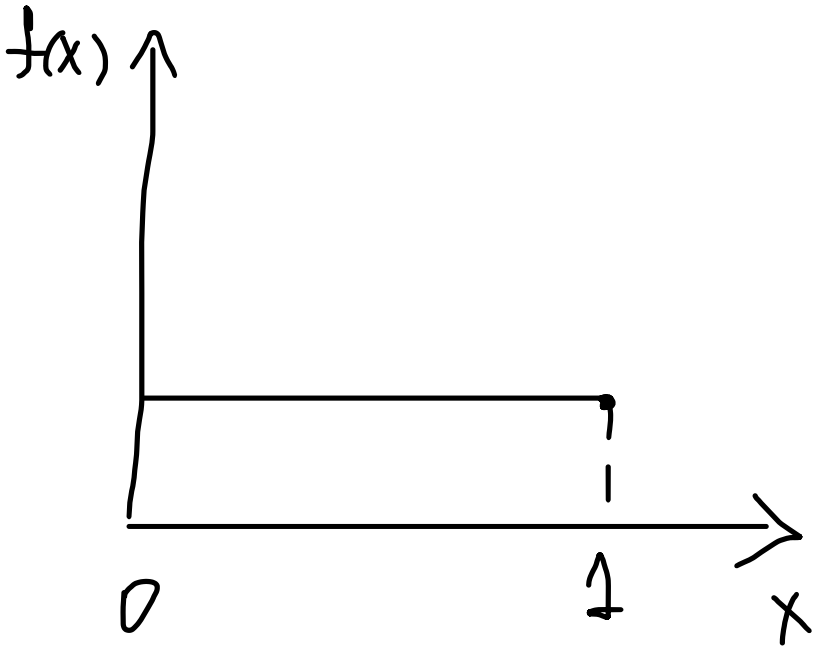


Плотность вероятности выпадения орла (честная монета)



Плотность вероятности вытащить черный шар из мешка (пропорция неизвестна)

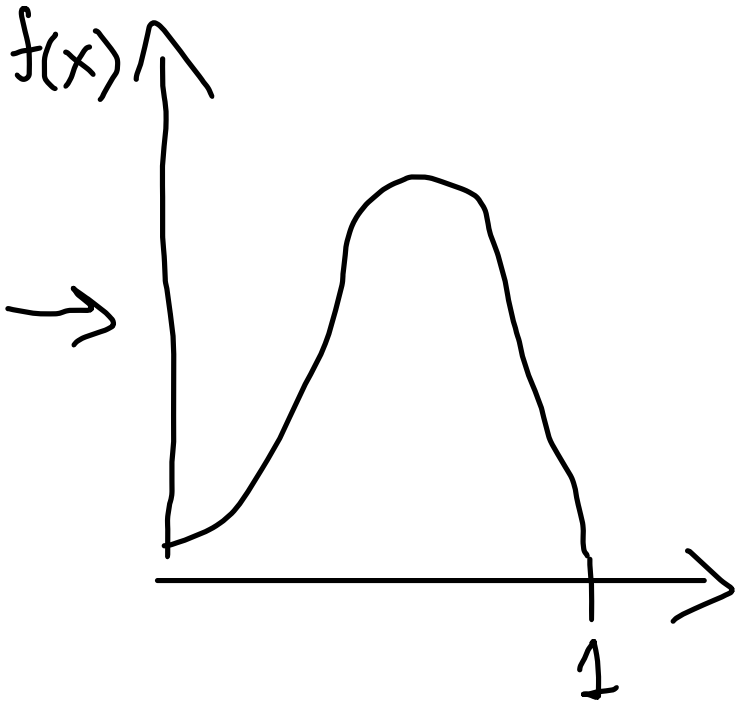
Априорное и апостериорное распределение



До получения данных

$\rightarrow X = 1,1,0,1,0,1 \rightarrow$

Мы «обновляем» свою неопределенность после получения новой выборки



После получения данных

Ранее делали так

- Ранее нам хотелось получить ответ на такой вопрос:

$$P(\theta > \theta_0 \mid y) - ?$$

- Однако «в лоб» мы этого сделать не могли, так как θ – это неизвестная константа;
- Чтобы разрешить эту ситуацию, мы придумали правила проверки статистических гипотез;
- А именно мы вводили нулевую и альтернативную гипотезу:

$$H_0: \theta = \theta_0 \quad vs \quad H_1: \theta \gtrless \theta_0$$

- Статистический тест помогал нам понять, насколько **значимо отличие** θ от θ_0;
- Однако ничего не говорил о том, насколько это различие **вероятно;**
- Иначе говоря, в рамках частотного подхода мы очень плохо умеем описывать эпистемическую неопределенность

Теперь будем так

- Не будем отделять θ и $\hat{\theta}$ друг от друга;
- Будем смотреть на θ как на случайную величину, а не на константу;
- Свое «знание» о θ мы будем выражать в априорном распределении $f(\theta)$;
- После мы будем получать данные и по формуле Байеса «обновлять свое знание», иначе говоря, считать апостериорное распределение:

$$f(\theta|y) = \frac{f(y|\theta) \cdot f(\theta)}{f(y)}$$

- Свои гипотезы мы можем тестировать, зная апостериорное распределение

Байесовский подход

- Формально модель задается как параметрическое семейство распределений с заданным на θ априорным распределением $p(\theta)$

- В процессе исследования какого-либо явления наша неопределенность обновляется по формуле Байеса, при этом полученное на предыдущем шаге апостериорное распределение является априорным на текущем

$$p(\theta) \xrightarrow{+y_1} p(\theta \mid y_1) \xrightarrow{+y_2} p(\theta \mid y_1, y_2) \rightarrow \ldots \xrightarrow{+y_k} p(\theta \mid y_1, \ldots, y_k)$$

Важно: на конечный результат не влияет порядок, в котором к нам приходят данные

Формула Байеса: напоминание

В «простой» записи

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Где:

P(A|B) – вероятность гипотезы A при наступлении события B;
P(A) – априорная вероятность гипотезы A
P(B|A) – вероятность наступления события B при истинности гипотезы A;
P(B) – полная вероятность наступления события B

Формула Байеса: напоминание

Пример

Есть два завода, они производят одинаковые детали. Известно, что на первом произведено 6000 деталей, на втором 4000. Доля брака на первом составляет 10%, на втором – 20%.
Выбрали случайным образом деталь, она оказалась не бракованная. Какова вероятность, что она произведена на первом заводе? На втором заводе?

$N = 10000$

$n_1 = 6000$ $\quad P_{\text{не брак}} = 0.9$

$n_2 = 4000$ $\quad P_{\text{не брак}} = 0.8$

В-ть, что деталь произведена на станке 1: $\frac{6000}{10000} = 0,6$

В-ть, что деталь произведена на станке 2: $\frac{4000}{10000} = 0,4$

В-ть вытащить не бракованную деталь из всей совокупности:

$$0,6 \cdot 0,9 + 0,8 \cdot 0,4 = 0,86$$

В-ть, что не бракованная со станка 1: $\frac{0,6 \cdot 0,9}{0,86} \approx 0,63$

В-ть, что не бракованная со станка 2: $\frac{0,4 \cdot 0,8}{0,86} \approx 0,37$

Формула Байеса: непрерывный случай

$$f(\theta|y) = \frac{f(y|\theta) \cdot f(\theta)}{f(y)}$$

$$f(y) = \int f(y|\theta) \cdot f(\theta) \, d\theta$$

const относительно θ

Формула Байеса

$$f(\theta|y) \propto f(y|\theta) \cdot f(\theta)$$

- На практике вычислением константы зачастую пренебрегают;
- Делают вычисления с точностью до константы;
- А затем восстанавливают константу (очень часто вычислительно сложная операция)

Формула Байеса

Формулу Байеса также можно также записать как:

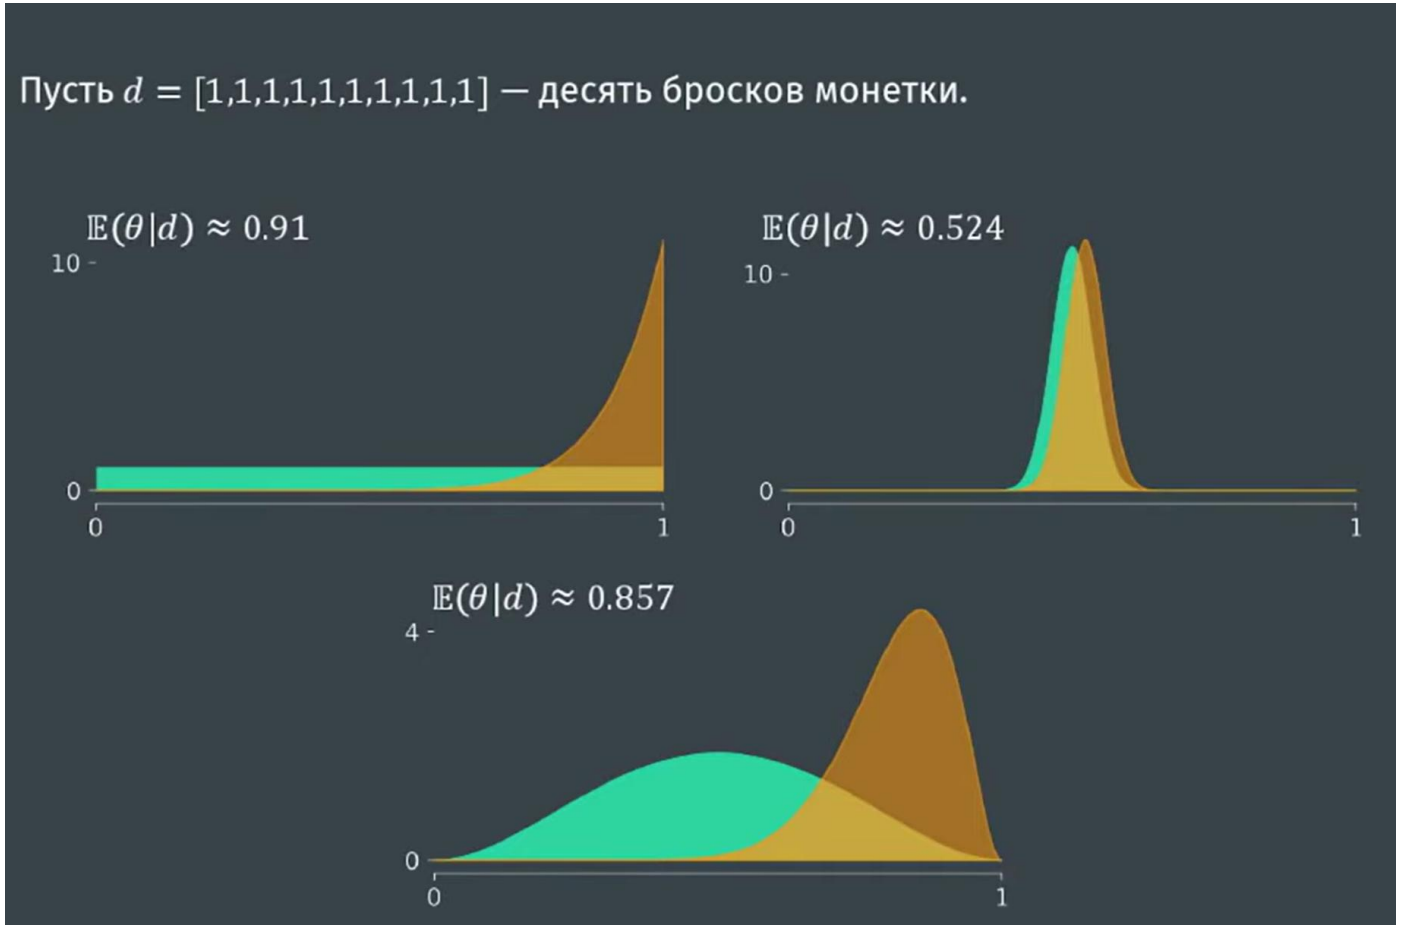
$$\text{Posterior} = \frac{\text{Likelihood} \cdot \text{Prior}}{\text{Evidence}}$$

Краткое резюме

- Байесовский подход – это один из способов оценить неизвестные параметры;
- В рамках Байесовского подхода можно оценивать любые «классические» модели

Виды априорных распределений

- Информативное
- Неинформативное
- Слабо информативное



Источник: 12. Байесовский подход

Виды априорных распределений

- Априорное распределение может быть одновременно и неинформативным, и информативным и слабо информативным;
- Если мы получаем данные из «разных» экспериментов

$$\text{апр} \sim \text{Beta}(3,3)$$

(y_i, n_i)	$15; 47$	$0; 5$	$124; 578$
y_i / n_i	$\approx 0{,}32$	0	$\approx 0{,}215$
$E(\theta \mid y_i, n_i)$	$0{,}36$	$0{,}375$	$\approx 0{,}219$

Источник: 12. Байесовский подход

Заметим, что:

$$\text{Posterior} = \frac{\text{Likelihood} \cdot \text{Prior}}{\text{Evidence}}$$

$$\text{Posterior} \propto \text{Likelihood} \cdot \text{Prior}$$

В случае равномерного:

$$\text{Posterior} \propto \text{likelihood} \cdot 1$$

- В случае, если априорное распределение – равномерное, то апостериорное распределение пропорционально правдоподобию
- Более того, если в качестве точечной оценки взять моду апостериорного распределения, то мы получим ММП!

Сопряженные распределения

- Если апостериорное распределение принадлежит тому же семейству распределений, что и априорное распределение (имеет тот же вид, но с другими параметрами), то это семейство распределений называется **сопряженным** семейству функций правдоподобия;

- При этом распределение называется сопряженным априорным распределением семейству функций правдоподобия;

- Плюс таких распределений в том, что есть готовые аналитические формулы обновления параметров для апостериорного распределения и не нужно на каждом шаге высчитывать интегралы

Таблицу и формулы для сопряженных распределений искать тут: https://clck.ru/3QoxEb

Предсказательное распределение

- Если мы умеем считать апостериорное распределение параметров, то можем посчитать и апостериорное распределение новых данных, которое называется предсказательным распределением:

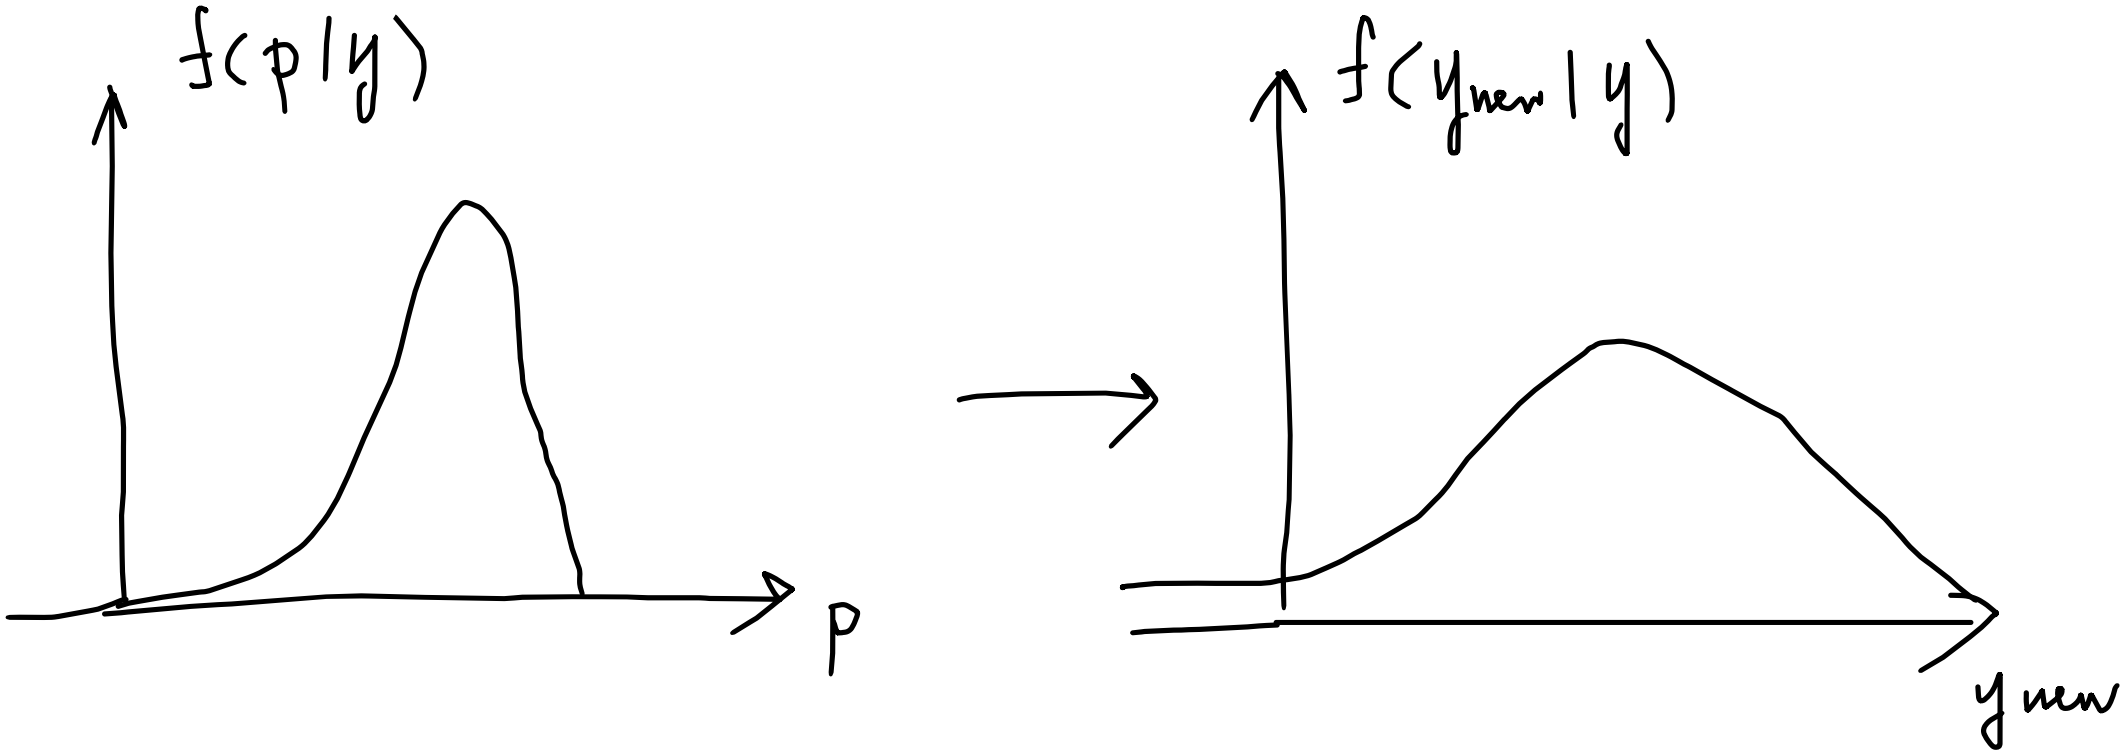
$$p(y_{new} \mid y) = \int_{\Theta} p(y_{new}, \theta \mid y)\, d\theta = \int_{\Theta} p(y_{new} \mid \theta, y)\, p(\theta \mid y)\, d\theta =$$

$$= \int_{\Theta} p(y_{new} \mid \theta)\, p(\theta \mid y)\, d\theta$$

модель данных — posterior

- Сэмплировать отсюда проще, чем считать интеграл!
- Генерируем новый/е параметр/ы θ_{NEW} из апостериорного распределения;
- Генерируем новое наблюдение из распределения с θ_{NEW}

Предсказательное распределение



Оценка качества модели

- Если модель «хорошая», то данные, сгенерированные из предсказательного распределения должны быть похожи на реальные данные: средние должны быть примерно средними, 50% достоверные интервалы содержать примерно половину наблюдений и тд…

- Похожесть можно оценить с помощью тестовых статистик, аналогично тому, как мы делали до этого

Оценка качества модели

- Выбираем статистику T, которая отслеживает различие между данными и моделью;

- Считаем вероятность получить на сгенерированных данных более экстремальное значение, чем то, что мы посчитали на реальных данных

$$P(T(y_{new}) > T(y) \mid y)$$

Апостериорное предсказательное p-value

Оценка качества модели

Как считать?

В теории так:

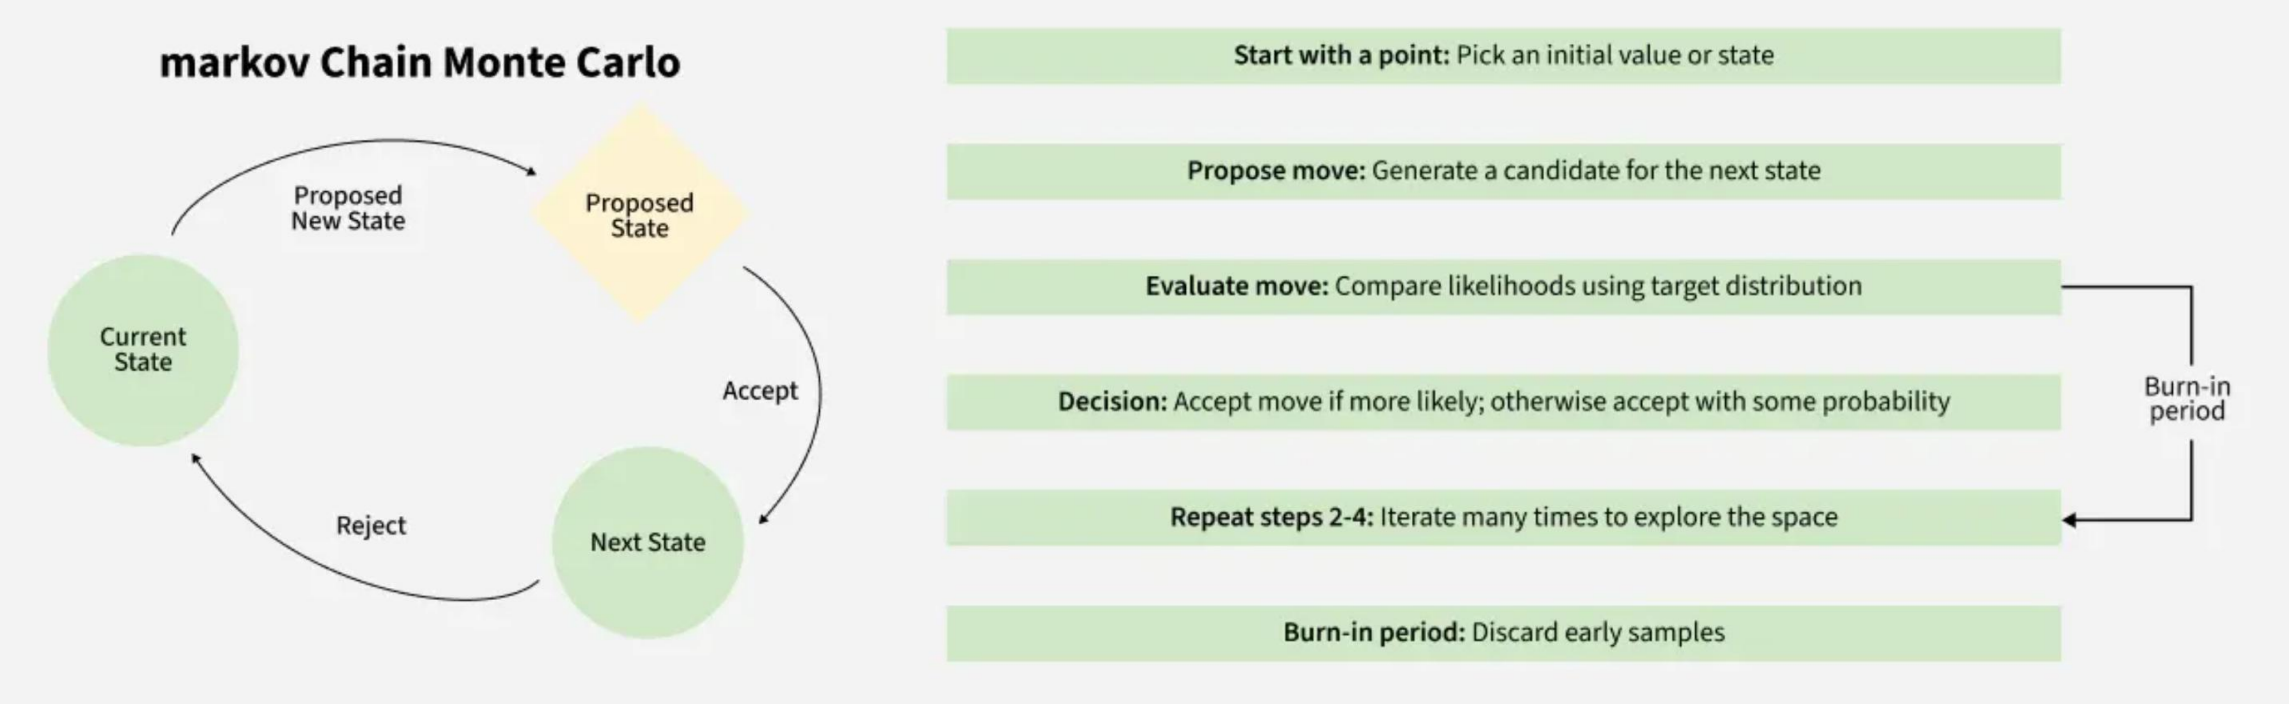
$$p = \int\int [T(y_{new}) \geq T(y)]\, p(y_{new}|\theta)\, p(\theta|y)\, y(y_{new})\, d\theta$$

На практике делают так:

1. Генерируют N параметров θ_{NEW} из апостериорного распределения;
2. Для каждого из них генерируют данные y_{NEW};
3. Для каждых сгенерированных данных y_{NEW} считают статистику T;
4. Значение «p-value» приближенно равно доле T, посчитанных по y_{NEW}, которые больше T, посчитанного по исходным данным

MCMC алгоритмы

Способ найти апостериорное распределение, не вычисляя его аналитически



Подробнее: https://clck.ru/3QvHzf

Дополнительно

- ВШЭ «Прикладная статистика», week 16: Прикладная статистика – YouTube
- ФКН ВШЭ, Дмитрий Ветров: «Байесовские методы» в машинном обучении: Курс «Байесовские методы в машинном обучении». Лекция 3 (Дмитрий Ветров)
- Кусочек про классификацию у К.Воронцова: Машинное обучение. Байесовская классификация. К.В. Воронцов, Школа анализа данных, Яндекс. – YouTube
- Очень хорошая пошаговая книжка для изучения байесовской статистики и алгоритмов: https://academic.oup.com/book/41940?login=false


ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ •